

Giới thiệu về Mô hình hóa Thống kê Cơ bản và Nâng cao

Tạo quy trình làm việc có thể tái tạo - Alexandre Courtiol

Mục lục

Tính tái tạo là gì?

Tại sao cần đảm bảo tính tái tạo cho quy trình làm

việc? Làm thế nào để đảm bảo tính tái tạo cho quy

trình làm việc? Giới thiệu nhanh về Quarto: Vượt

ra ngoài tính tái tạo

Tính tái tạo là gì?

Khả năng tái tạo không phải là một khái niệm nhị phân

Tính tái tạo được hiểu rõ nhất như một dải liên tục trong không gian đa chiều:

- **khả năng lặp lại:** liệu người khác có thể thu được kết quả tương tự khi có quyền truy cập vào cùng một dữ liệu không?
- **tính minh bạch:** các giải thích có đủ rõ ràng để người khác hiểu được không?
- **Khả năng tiếp cận:** liệu người khác có thể tìm thấy và tải xuống chính xác dữ liệu và mã nguồn đã được sử dụng hay không?
- **tính tương thích:** liệu họ có thể chạy mã nguồn trên một máy tính/hệ điều hành khác ngay hôm nay không?
- **Tính bền vững:** liệu mã nguồn có vẫn chạy được sau X năm kể từ khi các gói phần mềm được cập nhật không?
- **Khả năng tổng quát hóa:** liệu mã nguồn có thể được áp dụng cho một tập dữ liệu mới, tương tự không?

Khả năng tái tạo không phải là một khái niệm nhị phân

Khả năng tái tạo tốt nhất nên được xem như một dải liên tục trong không gian đa chiều:

- **Khả năng lặp lại:** liệu người khác có thể thu được kết quả tương tự khi có quyền truy cập vào cùng một dữ liệu không?
- **Tính minh bạch:** Các giải thích có đủ rõ ràng để người khác hiểu được không?
- **Khả năng tiếp cận:** liệu người khác có thể tìm thấy và tải xuống chính xác dữ liệu và mã nguồn đã được sử dụng không?
- **tính tương thích:** liệu họ có thể chạy mã nguồn trên một máy tính/hệ điều hành khác ngay hôm nay không?
- **Tính bền vững:** liệu mã nguồn có vẫn chạy được sau X năm kể từ khi các gói phần mềm được cập nhật không?
- **Khả năng tổng quát hóa:** Mã nguồn có thể được áp dụng cho một tập dữ liệu mới, tương tự không?

Lưu ý:

- các tên gọi là do tôi đặt (có nhiều từ đồng nghĩa)
- Việc cải thiện bất kỳ khía cạnh nào cũng đòi hỏi thời gian và nỗ lực có chủ đích, đồng thời dẫn đến những sự đánh đổi (ví dụ: việc cải thiện khả năng tổng quát hóa sẽ làm giảm tính rõ ràng)
- Trong phần giới thiệu rất ngắn này, tôi tập trung vào **khả năng lặp lại**

Tại sao phải làm cho quy trình làm việc có thể tái tạo được?

Tăng khả năng tái tạo mang lại lợi ích cho mọi người

Vì khả năng tái tạo đi kèm với chi phí, câu hỏi chính cần trả lời là:

ai sẽ được hưởng lợi từ nỗ lực làm cho mã của bạn có thể tái tạo?

Tăng khả năng tái tạo mang lại lợi ích cho mọi người

Vì khả năng tái tạo đi kèm với chi phí, câu hỏi chính cần trả lời là:

ai sẽ được hưởng lợi từ nỗ lực làm cho mã nguồn của bạn có khả năng tái tạo?

- chính bạn
 - ☒ chính bạn ngay lúc này
 - chính bạn trong tương lai gần (ví dụ: khi viết bài báo)
 - chính bạn trong tương lai xa (ví dụ: khi phân tích dữ liệu tương tự)

Tăng cường khả năng tái tạo mang lại lợi ích cho mọi người

Vì khả năng tái tạo đi kèm với chi phí, câu hỏi chính cần trả lời là:

ai sẽ được hưởng lợi từ nỗ lực làm cho mã nguồn của bạn có khả năng tái tạo?

- chính bạn
 - ☒ chính bạn ngay lúc này
 - chính bạn trong tương lai gần (ví dụ: khi viết bài báo)
 - chính bạn trong tương lai xa (ví dụ: khi phân tích dữ liệu tương tự)
- những người xung quanh bạn
 - người hướng dẫn / người phụ trách dự án
 - các đồng nghiệp và cộng sự của bạn
 - các nhà đánh giá, kiểm toán viên hoặc thẩm định viên tiềm năng

Tăng cường khả năng tái hiện mang lại lợi ích cho mọi người

Vì khả năng tái tạo đi kèm với chi phí, câu hỏi chính cần trả lời là:

Ai sẽ được hưởng lợi từ nỗ lực làm cho mã nguồn của bạn có khả năng tái tạo?

- chính bạn
 - ☒ **Hãy dành thời gian cho** bản thân ngay bây giờ
 - bản thân bạn trong tương lai gần (ví dụ: khi viết bài báo)
 - bản thân trong tương lai xa (ví dụ: phân tích dữ liệu tương tự)
- những người thân cận nhất của bạn
 - người hướng dẫn / người phụ trách dự án
 - các đồng nghiệp và cộng sự của bạn
 - các nhà đánh giá, kiểm toán viên hoặc thẩm định viên tiềm năng
- cộng đồng rộng lớn hơn
 - những người quan tâm đến dữ liệu của bạn
 - những người quan tâm đến vấn đề nghiên cứu của bạn
 - những người quan tâm đến phương pháp nghiên cứu của bạn

Tăng cường khả năng tái hiện mang lại lợi ích cho mọi người

Vì khả năng tái tạo đi kèm với chi phí, câu hỏi chính cần trả lời là:

Ai sẽ được hưởng lợi từ nỗ lực làm cho mã nguồn của bạn có thể tái tạo?

- chính bạn
 - ☑ chính bạn ngay lúc này
 - chính bạn trong tương lai gần (ví dụ: khi viết bài báo)
 - chính bạn trong tương lai xa (ví dụ: khi phân tích dữ liệu tương tự)
- những người xung quanh bạn
 - người hướng dẫn / người phụ trách dự án
 - các đồng nghiệp và cộng sự của bạn
 - các nhà đánh giá, kiểm toán viên hoặc thẩm định viên tiềm năng
- cộng đồng rộng lớn hơn
 - những người quan tâm đến dữ liệu của bạn
 - những người quan tâm đến vấn đề nghiên cứu của bạn
 - những người quan tâm đến phương pháp nghiên cứu của bạn

Lưu ý: nhiều câu trả lời có thể áp dụng đồng thời

Lợi ích chung của mã có thể lặp lại

So với việc chỉ tạo ra kết quả ngay lập tức (tức là lấy từ giao diện dòng lệnh R), việc viết các kịch bản/tài liệu có thể lặp lại mang lại những lợi ích sau:

- nó giúp tránh các lỗi lập trình
- quá trình thực hiện của bạn được theo dõi chính xác¹
- việc cập nhật kết quả sau khi cập nhật dữ liệu trở nên dễ dàng

¹ mã có thể lặp lại theo dõi những gì mã thực hiện chứ không phải cách mã thay đổi theo thời gian; việc này có thể được thực hiện bằng cách sử dụng hệ thống kiểm soát phiên bản, chẳng hạn như git/GitHub

Làm thế nào để tạo ra các quy trình làm việc có thể lặp lại?

Có thể sử dụng nhiều phương pháp khác nhau để cải thiện tính lặp lại của các quy trình làm việc dựa trên R

Công cụ	Lập trình có văn bản**	Cài đặt	Đường cong học tập
Tập lệnh R	không	đơn giản	thấp
Gói R*	có	khó	cao
sweave	có	trung bình	cao
rmarkdown/quarto	có	đơn giản	thấp/trung bình

*tức là một gói R cụ thể có mục tiêu chính là tái tạo kết quả của một quy trình làm việc

**kết hợp văn bản và mã

Có thể sử dụng nhiều phương pháp khác nhau để cải thiện khả năng lặp lại của các quy trình làm việc dựa trên R

Công cụ	Lập trình văn bản**	Thiết lập	Đường cong học tập
Tập lệnh R	không	đơn giản	thấp
Gói R*	có	khó	cao
sweave	có	trung bình	cao
rmarkdown/quarto	có	đơn giản	thấp/trung bình

*tức là một gói R cụ thể có mục tiêu chính là tái tạo kết quả của một quy trình làm việc

**kết hợp văn bản và mã nguồn

Kết luận:

- rmarkdown/quarto giúp cải thiện khả năng lặp lại với chi phí thấp
- Các lỗi cú pháp trong rmarkdown/quarto có thể gây bức bối, nhưng các mô hình ngôn ngữ lớn (LLMs) lại đặc biệt hiệu quả trong việc gỡ lỗi những vấn đề cụ thể này
- quarto có thể làm được những điều tương tự và thậm chí hơn cả rmarkdown, vì vậy tôi sẽ tập trung vào điều đó


Giới thiệu nhanh về quarto

Bài thực hành 1

- Tạo một tài liệu HTML mới bằng Quarto thông qua menu RStudio và hiển thị nó

Quarto là gì?

Quarto được định nghĩa là một “hệ thống xuất bản khoa học và kỹ thuật mã nguồn mở”



- Gói R {knitr} chuyển đổi các tệp Quarto sang định dạng Markdown
- Phần mềm pandoc chuyển đổi các tệp Markdown sang các định dạng đầu ra khác nhau

Cấu trúc chính

1. một tiêu đề xác định các thuộc tính chung của tài liệu, ở định dạng YAML
2. nội dung văn bản ở định dạng Markdown, HTML hoặc LaTeX
3. các đoạn mã máy tính

Phần tiêu đề

Ví dụ đơn giản

title: "Một tiêu đề nào đó"

format: html

Phần tiêu đề

Ví dụ thực tế

```
---
tiêu đề: "Giới thiệu về Mô hình hóa Thống kê Cơ bản và Nâng cao" phụ đề: "Tạo quy trình làm việc
có thể tái tạo"
tác giả: "Alexandre Courtiol" định dạng:
  beamer:
    tỷ lệ khung hình: 169 mục
    lục: true tùy chọn lớp: t
header-includes: |
  \setbeamertemplate{frametitle continuation}{}
  \setbeamertemplate{itemize items}[circle]
  \usepackage{caption}
  \captionsetup{labelformat=empty, justification=centering}
  \setbeamertemplate{footline}{%
    \hfill\usebeamercolor{fg}{số trang ở đầu/chân trang}%
    \usebeamerfont{số trang ở đầu/chân trang}%
    \insertframenumber{} / \inserttotalframenumber\kern1em\vskip2pt%
  }
  \usepackage{xcolor}
  \let\oldtexttt\texttt
  \renewcommand{\texttt}[1]{\colorbox{gray!20}{\oldtexttt{#1}}} tùy chọn trình soạn thảo:
  loại đầu ra khỏi: console
---
```

Lưu ý: đây là một phần của mã được sử dụng cho bài thuyết trình này

Phần tiêu đề

Phần tiêu đề là một thành phần đặc biệt dễ bị ảnh hưởng

- khoảng cách rất quan trọng
- Việc sao chép/dán tiêu đề giữa các tài liệu thường dẫn đến những thay đổi không mong muốn
- Các phiên bản hiện tại (?) của RStudio đôi khi tự động xóa các dòng khỏi tiêu đề một cách tự động (lỗi)
- phần lớn nội dung phải được điều chỉnh cho phù hợp với định dạng đầu ra đã chọn

Phần nội dung chính

Đây là phần dễ dàng

- viết văn bản thuần túy và sử dụng # , ## , ### để xác định thứ bậc của các phần (nếu thứ bậc bị lộn xộn, có thể là do một đoạn văn bản nằm ở của hệ thống phân cấp)
- sử dụng *text*, **text**, ***text*** để tạo *văn bản*, **văn bản** và ***văn bản*** tương ứng
- sử dụng [link_text](weblink) để tạo siêu liên kết
- sử dụng ![Chú thích hình](đường_dẫn_đến_hình/fig.png){chiều_cao=Xcm} để thêm một con số X cm về chiều cao*

Phần nội dung chính

Đây là phần dễ nhất

- viết văn bản thuần túy và sử dụng `#`, `##`, `###` để xác định thứ bậc của các phần (nếu thứ bậc bị lộn xộn, có thể là do một đoạn văn bản nằm ở của hệ thống phân cấp)
- sử dụng `*text*`, `**text**`, `***text***` để tạo *văn bản*, **văn bản** và ***văn bản*** tương ứng
- sử dụng `[link_text](weblink)` để tạo siêu liên kết
- sử dụng `![Chú thích hình](đường_dẫn_đến_hình/fig.png){chiều_cao=Xcm}` để thêm một hình có chiều cao Xcm*

*để thêm hình minh họa, bạn cũng có thể sử dụng các lệnh HTML, LaTeX hoặc R. Tôi thích sử dụng lệnh R do {knitr} cung cấp vì nó hoạt động tốt bất kể định dạng đầu ra là gì: bên trong một đoạn mã R (xem trang chiều tiếp theo), hãy sử dụng `knitr::include_graphics("path_to_figure/fig.png")`; bạn có thể điều chỉnh định dạng thông qua các tùy chọn đoạn mã (ví dụ: `#| out-height: Xcm`, `#| fig-align: center`)

Các khối mã R

```
```${r}  
#| option1: tham số cho option1
...
#| optionN: tham số cho optionN một số mã R
```
```

Ví dụ

```
```${r}  
#| nhãn: minh họa bộ lọc #| echo: true
#| thông báo: true
số_loài |> filter(năm == 2025)
```
```

Các đoạn mã R

```
```{r}  
#| option1: tham số cho option1
...
#| tùy chọnN: đối số cho tùy chọnN một số mã R
```
```

Ví dụ

```
```{r}  
#| nhãn: minh họa bộ lọc #| echo: true
#| thông báo: true
số_loài |> filter(năm == 2025)
```
```

Mẹo chuyên nghiệp:

- việc định nghĩa nhãn bằng cách sử dụng `#| label: some label` giúp xác định vị trí phát sinh vấn đề
- hiển thị tài liệu thường xuyên để phát hiện lỗi ngay sau khi chúng xuất hiện

Bài tập 2

1. đọc [trangquarto.org/docs/authoring/markdown-basics.html](https://quarto.org/docs/authoring/markdown-basics.html) từ đầu cho đến cuối phần có tiêu đề “Bảng”
2. Đọc toàn bộ trang quarto.org/docs/computations/r.html
3. Thêm một khối R, một hình ảnh và một số văn bản vào tài liệu Quarto của bạn và hiển thị lại
4. Chuyển định dạng từ HTML sang PDF và hiển thị tài liệu một lần nữa ²
5. Khám phá hướng dẫn của Quarto: quarto.org/docs/guide

² điều này sẽ yêu cầu cài đặt TinyTeX

Vượt ra ngoài khả năng lặp lại

Cách cải thiện các khía cạnh khác của khả năng tái tạo

- **Tính minh bạch:** giải thích *lý do tại sao* bạn làm điều đó chứ không chỉ *cách* bạn làm

Cách cải thiện các khía cạnh khác của khả năng tái tạo

- **Tính minh bạch:** ghi chép *lý do tại sao* bạn làm điều đó chứ không chỉ *cách* bạn làm
- **Khả năng tiếp cận:** lưu trữ dữ liệu và mã nguồn của bạn trên các nền tảng như GitHub, Zenodo, ...

Cách cải thiện các khía cạnh khác của khả năng tái tạo

- **minh bạch:** ghi chép *lý do tại sao* bạn làm điều đó chứ không chỉ *cách* bạn làm điều đó
- **Khả năng tiếp cận:** lưu trữ dữ liệu và mã nguồn của bạn trên các nền tảng như GitHub, Zenodo, ...
- **Tính tương thích:** Đảm bảo thử nghiệm mã nguồn của bạn trên các máy tính khác

Cách cải thiện các khía cạnh khác của khả năng tái tạo

- **Tính minh bạch:** ghi chép *lý do tại sao* bạn làm điều đó, chứ không chỉ *cách* bạn làm
- **Khả năng tiếp cận:** lưu trữ dữ liệu và mã nguồn của bạn trên các nền tảng như GitHub, Zenodo, ...
- **Tính tương thích:** Đảm bảo thử nghiệm mã nguồn của bạn trên các máy tính khác
- **Tính bền vững:** Hạn chế tối đa sự phụ thuộc vào các yếu tố bên ngoài; ít nhất hãy ghi lại phiên bản các gói bằng hàm `sessionInfo()`, hoặc tốt hơn là sử dụng các hệ thống như `{renv}` để lưu trữ và tải các phiên bản cụ thể của các gói R; để đảm bảo tính bền vững lâu dài, hãy tìm hiểu cách xây dựng các container (ví dụ: Docker)

Cách cải thiện các khía cạnh khác của khả năng tái tạo

- **Tính minh bạch:** ghi lại *lý do tại sao* bạn làm điều gì đó chứ không chỉ *cách* bạn làm điều đó
- **Khả năng truy cập:** lưu trữ dữ liệu và mã nguồn của bạn trên các nền tảng như GitHub, Zenodo, ...
- **Tính tương thích:** Đảm bảo thử nghiệm mã nguồn của bạn trên các máy tính khác
- **Tính bền vững:** giảm thiểu sự phụ thuộc vào các yếu tố bên ngoài; ít nhất hãy ghi lại phiên bản gói bằng hàm `sessionInfo()`, hoặc tốt hơn là sử dụng các hệ thống như {renv} giúp lưu trữ và tải các phiên bản cụ thể của các gói R; để đảm bảo tính bền vững lâu dài, hãy tìm hiểu cách xây dựng các container (ví dụ: Docker)
- **Khả năng tổng quát hóa:** thiết kế các hàm, không mã hóa cứng các tham số, không sử dụng chỉ số

Cách cải thiện các khía cạnh khác của khả năng tái tạo

- **Tính minh bạch:** Hãy ghi chép *lý do tại sao* bạn làm điều gì đó, chứ không chỉ *cách* bạn thực hiện nó
- **Khả năng truy cập:** Lưu trữ dữ liệu và mã nguồn của bạn trên các nền tảng như GitHub, Zenodo, ...
- **Tương thích:** Đảm bảo thử nghiệm mã nguồn của bạn trên các máy tính khác
- **Tính bền vững:** Giảm thiểu sự phụ thuộc vào các yếu tố bên ngoài; ít nhất hãy ghi lại phiên bản các gói bằng hàm `sessionInfo()`, hoặc tốt hơn là sử dụng các hệ thống như {renv} để lưu trữ và tải các phiên bản cụ thể của các gói R; để đảm bảo tính bền vững lâu dài, hãy tìm hiểu cách xây dựng các container (ví dụ: Docker)
- **Khả năng tổng quát hóa:** thiết kế các hàm, không mã hóa cứng các tham số, không sử dụng chỉ số

Cách cải thiện các khía cạnh khác của khả năng tái tạo

- **Tính minh bạch:** ghi lại *lý do tại sao* bạn làm điều gì đó chứ không chỉ *cách* bạn làm điều đó
- **Khả năng tiếp cận:** lưu trữ dữ liệu và mã nguồn của bạn trên các nền tảng như GitHub, Zenodo, ...
- **Tính tương thích:** Đảm bảo thử nghiệm mã nguồn của bạn trên các máy tính khác
- **Tính bền vững:** Giảm thiểu sự phụ thuộc vào các thành phần bên ngoài; ít nhất hãy ghi lại phiên bản các gói bằng hàm `sessionInfo()`, hoặc tốt hơn là sử dụng các hệ thống như {renv} để lưu trữ và tải các phiên bản cụ thể của các gói R; để đảm bảo tính bền vững lâu dài, hãy tìm hiểu cách xây dựng các container (ví dụ: Docker)
- **Khả năng tổng quát hóa:** Thiết kế các hàm, không mã hóa cứng các tham số, không sử dụng chỉ số

Lưu ý:

- Nhiều cải tiến trong số này có thể đạt được với chi phí tối thiểu
- Hãy nhớ rằng khả năng lặp lại là một quá trình liên tục (ví dụ: mã càng có tính tổng quát cao mà người ta mong muốn, thì càng phải bỏ nhiều công sức vào việc tạo ra mã nguồn đó)

Có câu hỏi nào không?