

Giới thiệu về Mô hình hóa Thống kê Cơ bản và Nâng cao

Từ LM đến GLM -

Alexandre Courtiol

Mục lục

Mô hình tuyến tính (LM) Giải thích

các hệ số Mô hình tuyến tính tổng quát

(GLM)

Các phép kiểm định

Xây dựng mô hình

Các giả định

Mô hình chiếm dụng môi trường sống

Kết luận

Mô hình tuyến tính (LM)

LM — Mô hình thống kê là gì?

Mô hình thống kê

một mô tả gần đúng về *quá trình tạo ra dữ liệu*, tức là một sự gần đúng về cách thế giới tạo ra dữ liệu

LM — Mô hình thống kê là gì?

Mô hình thống kê

một mô tả gần đúng về *quá trình tạo ra dữ liệu*, tức là một sự gần đúng về cách thế giới tạo ra dữ liệu

Lưu ý: Việc xem các mô hình như một *quá trình tạo ra dữ liệu* có thể không trực quan ngay từ đầu, nhưng điều này rất quan trọng cả về mặt khái niệm lẫn thực tiễn!

Đặc biệt, điều này giúp

- giải thích chính xác các tham số mô hình lập
- kế hoạch kích thước mẫu trước khi thu thập dữ liệu
- kiểm tra độ bao phủ của các khoảng tin cậy (tức là xem chúng có hoạt động như dự định hay không)
- kiểm tra độ bền vững của phép kiểm định thống kê (tức là kiểm tra tỷ lệ dương tính giả)
- thực hiện các kiểm tra dự đoán trước và sau trong quá trình phân tích Bayes

LM — Mô hình tuyến tính (LM) là gì?

Mô hình tuyến tính

một quá trình tạo dữ liệu được tạo ra bởi một *hàm tuyến tính*: dữ liệu được tạo ra từ một tập hợp các hạng bằng cách nhân mỗi hạng với một hằng số (một tham số mô hình) và cộng chúng lại với nhau

LM — Mô hình tuyến tính (LM) là gì?

Mô hình tuyến tính

một quá trình tạo dữ liệu được tạo ra bởi một *hàm tuyến tính*: dữ liệu được tạo ra từ một tập hợp các hạng bằng cách nhân mỗi hạng với một hằng số (một tham số mô hình) và cộng chúng lại với nhau

Lưu ý:

- các mô hình tuyến tính bao gồm hồi quy tuyến tính cổ điển tạo thành một đường thẳng, nhưng cũng nhiều mô hình khác (ví dụ: các đa thức là tuyến tính nhưng lại không tạo thành đường thẳng) → LM là tuyến tính theo các tham số (không nhất thiết phải tuyến tính theo các biến)
- phần lớn khó khăn mà mọi người gặp phải khi xử lý các mô hình phức tạp hơn (ví dụ: Mô hình Tuyến tính Tổng quát, Mô hình Hiệu ứng Hỗn hợp Tuyến tính, Mô hình Phân cấp) thường xuất phát từ việc chưa hiểu đủ về LM

LM — các ký hiệu của LM: ký hiệu đơn giản

$$y_i = \beta_0 + \beta_1 \times x_{1,i} + \beta_2 \times x_{2,i} + \cdots + \beta_n \times x_{n,i} + \epsilon_i \text{ với } \epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

LM — các ký hiệu của LM: ký hiệu đơn giản

$$y_i = \beta_0 + \beta_1 \times x_{1,i} + \beta_2 \times x_{2,i} + \dots + \beta_n \times x_{n,i} + \epsilon_i \text{ với } \epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

y_i = biến phản ứng / biến phụ thuộc / các quan sát cần giải thích

- β_j = các tham số mô hình / hệ số hồi quy
- x = các biến hồi quy / hằng số được suy ra từ các biến dự báo (còn gọi tắt là biến dự báo)
- ϵ_i = sai số / sai số dư

LM — các ký hiệu của LM: ký hiệu đơn giản

$$y_i = \beta_0 + \beta_1 \times x_{1,i} + \beta_2 \times x_{2,i} + \dots + \beta_p \times x_{p,i} + \epsilon_i \text{ với } \epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

y_i = biến phản ứng / biến phụ thuộc / các quan sát cần giải thích

- β_j = các tham số mô hình / hệ số hồi quy
- x = các biến hồi quy / hằng số được suy ra từ các biến dự báo (còn gọi tắt là biến dự báo)
- ϵ_i = sai số / sai số dự

Lưu ý:

- đây là ký hiệu mà các nhà sinh học nên sử dụng trong bài báo/luận văn của mình để mô tả mô hình của họ; các biến giải thích đôi khi được xác định trực tiếp từ các cột trong tập dữ liệu của bạn (tức là các biến dự báo), nhưng không phải lúc nào cũng vậy (sẽ nói thêm về điều này sau)
- khi các tham số chưa được biết mà được ước lượng, chúng nên được đánh dấu bằng dấu mũ (ví dụ: β_0) và ϵ_i (còn khi được gọi là ϵ_i) thường trở thành e_i hoặc τ_i

LM — ký hiệu của LM: ký hiệu R thông thường

$$y \sim x_1 + x_2 + \dots + x_p$$

Lưu ý:

- các tham số và hằng số sai số không được ghi ra

LM — các ký hiệu của LM: ký hiệu ma trận

$$Y = E\beta + \epsilon$$

$$\begin{array}{c}
 \begin{pmatrix} y^1 \\ y^2 \\ \vdots \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ \vdots \end{pmatrix} \begin{pmatrix} x^{1,1} & x^{1,2} & \dots & x^{1,p} \\ x^{2,1} & x^{2,2} & \dots & x^{2,p} \\ x^{3,1} & x^{3,2} & \dots & x^{3,p} \\ \dots & \dots & \dots & \dots \\ x_{n,1} & x_{n,2} & \dots & x_{n,p} \end{pmatrix} \begin{pmatrix} \beta^0 \\ \beta^1 \\ \beta^2 \\ \vdots \end{pmatrix} + \begin{pmatrix} \epsilon^1 \\ \epsilon^2 \\ \vdots \end{pmatrix} \\
 \mathbf{y}_n / \quad \mathbf{1} \quad \mathbf{x}_n / \quad \mathbf{\beta}_p / \quad \mathbf{\epsilon}_n /
 \end{array}$$

LM — các ký hiệu của LM: ký hiệu ma trận

$$Y = E\beta + \epsilon$$

$$\begin{matrix} \begin{matrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{matrix} & = & \begin{matrix} \begin{matrix} x_{1,1} & x_{1,2} & \dots & x_{1,p} \end{matrix} \\ \begin{matrix} x_{2,1} & x_{2,2} & \dots & x_{2,p} \end{matrix} \\ \vdots & & \vdots & \\ \begin{matrix} x_{n,1} & x_{n,2} & \dots & x_{n,p} \end{matrix} \end{matrix} \begin{matrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{matrix} + \begin{matrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \vdots \\ \epsilon_n \end{matrix}$$

Y = vector các giá trị quan sát

- E = một ma trận được gọi là ma trận thiết kế (hoặc ma trận mô hình)
- β = vector các tham số mô hình
- ϵ = vector sai số, với $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$

Lưu ý: đây là ký hiệu dành cho các nhà thống kê và nhà khoa học máy tính, đặc biệt hữu ích khi giải thích các hệ số

LM — quy trình tạo dữ liệu: mô phỏng dữ liệu

Hãy chuyển sang **chế độ "Thần"** chúng ta giả định rằng **Emerald Lion** (một nữ thần) biết thể giới của cô ấy tạo ra dữ liệu như thế nào; cô ấy cho chúng ta biết rằng trong thế giới của cô ấy, người ngoài hành tinh tiếp tục phát triển theo số lượng con người mà họ ăn như sau:

$$\begin{cases} \text{kích thước}_i = 50 + 1,5 \times \text{humans_eaten}_i + \epsilon_i \\ \epsilon_i \sim \mathcal{N}(0, \sigma^2 = 4) \end{cases}$$

LM — quá trình tạo dữ liệu: mô phỏng dữ liệu

Hãy chuyển sang **chế độ Thần** chúng ta giả định rằng **Emerald Lion** (một nữ thần) biết cách thể giới của cô ấy tạo ra dữ liệu; cô ấy đã thông báo cho chúng ta rằng trong thế giới của cô ấy, người ngoài hành tinh tiếp tục phát triển theo số lượng con người mà họ ăn như sau:

$$\begin{cases} \text{kích thước}_i = 50 + 1,5 \times \text{số người bị ăn}_i + \epsilon_i \\ \epsilon_i \sim \mathcal{N}(0, \sigma^2 = 4) \end{cases}$$

Do đó, chúng ta có thể tạo ra 12 người ngoài hành tinh đã ăn từ 1 đến 3 người theo công thức của E.L.:

```
set.seed(2) N
<- 12
Alien <- tibble(humans_eaten = rep(1:3, each = 4), # phương án thay thế, ví dụ: rpois() cũng được intercept
               = 50, slope = 1.5,
               error = rnorm(n = N, mean = 0, sd = 2), # phải là hàm rnorm! size =
               intercept + slope*humans_eaten + error)
```

LM — quy trình tạo dữ liệu: mô phỏng dữ liệu

Hãy chuyển sang **chế độ Thần** chúng ta giả định rằng **Emerald Lion** (một nữ thần) biết thể giới của cô ấy tạo ra dữ liệu như thế nào; cô ấy cho chúng ta biết rằng trong thế giới của cô ấy, người ngoài hành tinh tiếp tục phát triển theo số lượng con người mà họ ăn như sau:

$$\begin{cases} \text{kích thước}_i = 50 + 1,5 \times \text{số người bị ăn}_i + \epsilon_i \\ \epsilon_i \sim \mathcal{N}(0, \sigma^2 = 4) \end{cases}$$

Do đó, chúng ta có thể tạo ra 12 người ngoài hành tinh đã ăn từ 1 đến 3 người theo công thức của E.L.:

```
set.seed(2) N
<- 12
Alien <- tibble(humans_eaten = rep(1:3, each = 4), # phương án thay thế, ví dụ: rpois() cũng được intercept
               = 50, slope = 1.5,
               error = rnorm(n = N, mean = 0, sd = 2), # phải là hàm rnorm! size =
               intercept + slope*humans_eaten + error)
```

Lưu ý: chúng ta cũng có thể viết 2 dòng cuối như sau:

```
size <- rnorm(n = 12, mean = intercept + slope*humans_eaten, sd = 2)
```

LM — quy trình tạo dữ liệu: kiểm tra dữ liệu

Dữ liệu mô phỏng

Alien

```
# Một bảng: 12 x 5
số_người_bị_ăn hàng_số_cắt độ_dốc sai_số kích_thước
      <int>      <dbl> <dbl> <dbl> <dbl>
1          1          50    1,5 -1,79    49,7
2          1           50    1,5  0,370  51,9
3          1          50    1,5  3,18    54,7
4          1          50    1,5 -2,26    49,2
5          2          50    1,5 -0,161  52,8

# i 7 hàng nữa
```

Các cột nào hiển thị các *tham số mô hình*?

- Các cột nào hiển thị *biến giải thích* (ở đây = biến dự báo)?
Các cột nào hiển thị *sai số*?
- Các cột nào hiển thị *biến phản hồi*?

Bài tập 1

Dữ liệu mô phỏng

Alien

Một bảng: 12 x 5

số người bị ăn điểm cắt độ dốc sai số kích thước

	<int>	<dbl>	<dbl>	<dbl>	<dbl>
1	1	50	1,5	-1,79	49,7
2	1	50	1,5	0,370	51,9
3	1	50	1,5	3,18	54,7
4	1	50	1,5	-2,26	49,2
5	2	50	1,5	-0,161	52,8

i 7 hàng nữa

Các cột nào hiển thị các *tham số mô hình*? Các cột nào

- hiển thị *biến giải thích* (ở đây là biến dự báo)? Các cột nào
- hiển thị *sai số*?

- Các cột nào hiển thị *biến phản ứng*?

Giá trị phản hồi trung bình sẽ là bao nhiêu đối với một người ngoài hành tinh không ăn thịt

- người? *Giá trị phản hồi trung bình* sẽ là bao nhiêu đối với một người ngoài hành tinh ăn 2 người?

Giải pháp

- Giá trị trung bình của phản ứng sẽ là bao nhiêu đối với một người ngoài hành tinh không ăn người? $\text{mean}(y \mid \text{humans_eaten} = 0) = 50 + 1,5 \times 0 = 50$

Giải pháp

- *Giá trị phản ứng trung bình* sẽ là bao nhiêu đối với một người ngoài hành tinh không ăn thịt người? $\text{mean}(y \mid \text{humans_eaten} = 0) = 50 + 1,5 \times 0 = 50$
- *Giá trị trung bình của phản ứng* sẽ là bao nhiêu đối với một người ngoài hành tinh ăn 2 người? $\text{mean}(y \mid \text{humans_eaten} = 2) = 50 + 1,5 \times 2 = 53$

LM — Phù hợp mô hình: phương pháp thống kê tần

số

Trong thực tế, các tham số mô hình là **chưa biết**, vì vậy chúng ta phải ước lượng chúng –
→ đó chính là mục đích của việc mô hình hóa thống kê...→ Chế độ "God mode" hiện đã tắt

LM — Phù hợp mô hình: phương pháp thống kê tần

số

Trên thực tế, các tham số mô hình là *chưa biết*, vì vậy chúng ta phải ước lượng chúng –
→ đó chính là mục đích của việc mô hình hóa thống kê... → chế độ "God mode" hiện đã tắt

- trong thống kê tần số, *việc ước lượng mô hình* có nghĩa là ước lượng các giá trị của các tham số mô hình sao cho xác suất dữ liệu

```
fit_alien_lm <- lm(size ~ humans_eaten, data = Alien)
summary(fit_alien_lm) # hoặc coef(fit_alien_lm) nếu chỉ muốn tập trung vào các hệ số
```

Gọi:

```
lm(formula = size ~ humans_eaten, data = Alien)
```

Dự lượng:

	Tối thiểu	1Q	Trung vị	3Q	Tối đa
	-1,9710	-1,1744	-0,4725	0,7023	3,4655

Hệ số:

	Giá trị ước lượng	Sai số chuẩn	Giá trị t	Xác suất
(Pr(> t)) (Hàng số)	48,8353	1,3454	36,298	5,99e-12 ***
số người bị ăn thịt	2,3749	0,6228	3,813	0,00341 **

Mã ý nghĩa: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1

Sai số chuẩn dư: 1,762 trên 10 bậc tự do
Hệ số R-squared đa biến: 0,5925,
Hệ số R-squared điều chỉnh: 0,5518
Thống kê F: 14,54 trên 1 và 10 bậc tự do, giá trị p: 0,003411

LM — Phù hợp mô hình: Giới thiệu về phương pháp bình phương tối thiểu thông thường (OLS)

Trong LM (nhưng không phải GLM), việc tìm các ước lượng tối đa hóa xác suất dữ liệu dựa trên mô hình (tức là tối đa hóa hàm khả năng) tương đương với việc tối thiểu hóa tổng bình phương, vì vậy đây chính là những gì hàm `lm()` thực sự thực hiện vì nó đơn giản hơn về mặt tính toán so với việc tính toán hàm khả năng

Để minh họa rõ nhất khái niệm OLS, chúng ta cần mô phỏng dữ liệu có độ phân tán rộng hơn một chút


```
set.seed(123)
Alien2 <- tibble(humans_eaten = 1:12, intercept = 50, slope = 1.5,
                 size = rnorm(n = 12, mean = intercept + slope*humans_eaten, sd = 4))
fit_alien2_lm <- lm(size ~ humans_eaten, data = Alien2)
```

LM — ước lượng mô hình: phần giới thiệu về phương pháp bình phương tối thiểu thông thường (OLS)

Trong LM (nhưng không phải GLM), việc tìm các ước lượng tối đa hóa xác suất của dữ liệu dựa trên mô hình (tức là tối đa hóa hàm khả năng) tương đương với việc tối thiểu hóa tổng bình phương, vì vậy đây chính là những gì hàm `lm()` thực sự thực hiện vì nó đơn giản hơn về mặt tính toán so với việc tính toán hàm khả năng

Để minh họa rõ nhất khái niệm OLS, chúng ta cần mô phỏng dữ liệu có độ phân tán rộng hơn một chút

```
set.seed(123)
Alien2 <- tibble(humans_eaten = 1:12, intercept = 50, slope = 1.5,
                 size = rnorm(n = 12, mean = intercept + slope*humans_eaten, sd = 4))
fit_alien2_lm <- lm(size ~ humans_eaten, data = Alien2)
```




Dữ liệu trên mô hình phù hợp nhất

LM — ước lượng mô hình: phần giới thiệu về phương pháp bình phương tối thiểu thông thường (OLS)


Trong LM (nhưng không phải GLM), việc tìm các ước lượng tối đa hóa xác suất của dữ liệu dựa trên mô hình (tức là tối đa hóa hàm khả năng) tương đương với việc tối thiểu hóa tổng bình phương, vì vậy đây chính là những gì hàm `lm()` thực sự thực hiện vì nó đơn giản hơn về mặt tính toán so với việc tính toán hàm khả năng

Để minh họa rõ nhất khái niệm OLS, chúng ta cần mô phỏng dữ liệu có độ phân tán rộng hơn một chút

```
set.seed(123)
Alien2 <- tibble(humans_eaten = 1:12, intercept = 50, slope = 1.5,
                 size = rnorm(n = 12, mean = intercept + slope*humans_eaten, sd = 4))
fit_alien2_lm <- lm(size ~ humans_eaten, data = Alien2)
```



Dữ liệu trên đường hồi quy tốt nhất




Dự đoán phương trên mô hình phù hợp nhất

LM — Phù hợp mô hình: Chương phụ về phương pháp bình phương tối thiểu thông thường (OLS)


Trong LM (nhưng không phải GLM), việc tìm các ước lượng tối đa hóa xác suất dữ liệu dựa trên mô hình (tức là tối đa hóa hàm khả dĩ) tương đương với việc tối thiểu hóa tổng bình phương, do đó đây chính là điều mà hàm `lm()` thực hiện vì nó đơn giản hơn về mặt tính toán so với việc tính toán hàm khả dĩ

Để minh họa rõ nhất khái niệm OLS, chúng ta cần mô phỏng dữ liệu có độ phân tán rộng hơn một chút

```
set.seed(123)
Alien2 <- tibble(humans_eaten = 1:12, intercept = 50, slope = 1.5,
                 size = rnorm(n = 12, mean = intercept + slope*humans_eaten, sd = 4))
fit_alien2_lm <- lm(size ~ humans_eaten, data = Alien2)
```



Hồi quy bình phương trên mô hình không phù hợp




Hồi quy bình phương trên mô hình phù hợp nhất

LM — việc hiệu chỉnh mô hình: kết quả hiệu chỉnh so với giá trị thực,

và t Alien |> # Chúng ta quay lại sử dụng dữ liệu và mô hình ban đầu!

```
mutate(mean_response_values = intercept + slope * humans_eaten, # giá trị thực trong quần thể fitted_values =  
  fitted(fit_alien_lm),  
  residuals = residuals(fit_alien_lm)) -> Alien
```




- một *dự đoán* là giá trị trung bình của phản ứng do mô hình đưa ra cho một số lượng lớn các quan sát có cùng đặc điểm biến độc lập (tức là bất kỳ điểm nào trên đường san hô đều là một dự đoán)
- *giá trị được ước lượng* là *dự đoán* tại các đặc điểm biến độc lập đã quan sát được (tức là chỉ các điểm tương ứng với 1, 2 và 3 người trên đường cong san hô)
- *Dự lượng* là sự chênh lệch giữa một quan sát và giá trị ước lượng của nó (ví dụ: giá trị quan sát_i giá trị dự đoán_i sai số_i)

LM — Phù hợp mô hình: Phương pháp Bayes với {brms}

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Trước tiên, hãy sử dụng {brms}, công cụ này đơn giản hơn {nimble} nhưng chỉ xử lý được một tập hợp mô hình nhỏ hơn

```
library(brms) # Mô hình hồi quy Bayes sử dụng Stan
fit_alien_lm_brms <- brm(size ~ humans_eaten, data = Alien)
mcmc_plot(fit_alien_lm_brms, type = "trace") # có thể tạo ra nhiều biểu đồ chẩn đoán
```




LM — Phù hợp mô hình: Phương pháp Bayes với {brms}

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Dưới đây là các phân phối hậu nghiệm

```
mcmc_plot(fit_alien_lm_brms, type = "dens_overlay") # có thể tạo ra nhiều biểu đồ chẩn đoán
```



LM — Phù hợp mô hình: Phương pháp Bayes với {brms}

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Dưới đây là tóm tắt về các phân phối hậu nghiệm

```
summary(fit_alien_lm_brms) # hoặc fixef(fit_alien_lm_brms) để tập trung vào các hệ số
```

Họ: Gaussian Liên kết: mu =

danh tính

Công thức: size ~ humans_eaten

Dữ liệu: Alien (Số quan sát: 12)

Lần rút mẫu: 4 chuỗi, mỗi chuỗi có iter = 2000; warmup = 1000; thin = 1; tổng số lần
rút mẫu sau giai đoạn làm nóng = 4000

Hệ số hồi quy:

	Ước lượng	Sai số	ước lượng	Giới hạn dưới 95% CI	Giới hạn trên 95% CI	Rhat
Bulk_ESS	Tail_ESS	Hàng số	48,83	1,51	45,81	51,85
	2.454					1,00
số người bị ăn thịt	2,38	0,70	0,99	3,76	1,00	3166
						2281

Các thông số phân phối khác:

Giá trị ước lượng,	Sai số ước lượng,	Giới hạn dưới của khoảng tin cậy 95%,			
Giới hạn trên của khoảng tin cậy 95%,	Rhat,	Bulk_ESS,	Tail_ESS,	sigma	1,92
0.46	1.26	3.03	1.00	2388	2555

Các kết quả hòa được lấy mẫu bằng phương pháp sampling(NUTS). Đối với mỗi tham số, Bulk_ESS và Tail_ESS là các thước đo kích thước mẫu hiệu quả, còn Rhat là hệ số giảm quy mô tiềm năng trên các chuỗi phân tách (khi hội tụ, Rhat = 1).

LM — Phù hợp mô hình: Phương pháp Bayes với {nimble}

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Bây giờ chúng ta hãy sử dụng {nimble}

```
library(nimble)
library(posterior)
library(bayesplot)

code <- nimbleCode({
  for (i in seq_len(N)) { # mô hình mô phỏng quá trình tạo dữ liệu size[i] ~ dnorm(mean =
    intercept + slope*humans_eaten[i], sd = sigma)
  }
  # phân phối a priori
  intercept ~ dnorm(mean = 50, sd = 5) slope ~
  dnorm(mean = 0, sd = 5) sigma ~ dunif(min =
  0, max = 5)
})

constants <- list(N = nrow(Alien), humans_eaten = Alien$humans_eaten) inits <-

list(intercept = mean(Alien$size), slope = 0, sigma = 1)
```

LM — Phù hợp mô hình: Kiểm tra dự đoán trước

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Trước khi ước lượng mô hình, hãy đảm bảo rằng các phân phối tiên nghiệm của chúng ta không quá mơ hồ


```
set.seed(123) n_sims <-  
1000  
  
prior <- tibble(sim = seq_len(n_sims),  
  intercept = rnorm(n_sims, mean = 50, sd = 5), slope =  
  rnorm(n_sims, mean = 0, sd = 5), sigma = runif(n_sims,  
  min = 0, max = 5))  
  
humans_eaten_possible <- min(Alien$humans_eaten):max(Alien$humans_eaten)  
  
expand_grid(prior, humans_eaten = humans_eaten_possible) |> mutate(size =  
  intercept[sim] + slope[sim]*humans_eaten,  
  resp = size + rnorm(n = n(), 0, sigma[sim])) -> prior_pred  
  
ggplot(prior_pred, aes(x = humans_eaten, y = size)) + geom_line(aes(group = sim),  
  linewidth = 0.1) + geom_hline(yintercept = 0, linetype = "dashed") +  
  geom_point(aes(group = NULL), colour = "#3333B3", data = Alien)
```

LM — Phù hợp mô hình: Kiểm tra dự đoán trước

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Trước khi ước lượng mô hình, hãy đảm bảo rằng các phân phối tiên nghiệm của chúng ta không quá mơ hồ

```
set.seed(123) n_sims <-  
1000  
  
prior <- tibble(sim = seq_len(n_sims),  
                intercept = rnorm(n_sims, mean = 50, sd = 5), slope =  
                rnorm(n_sims, mean = 0, sd = 5), sigma = runif(n_sims,  
                min = 0, max = 5))  
  
humans_eaten_possible <- min(Alien$humans_eaten):max(Alien$humans_eaten)  
  
expand_grid(prior, humans_eaten = humans_eaten_possible) |> mutate(size =  
  intercept[sim] + slope[sim]*humans_eaten,  
  
  resp = size + rnorm(n = n(), 0, sigma[sim])) -> prior_pred  
  
ggplot(prior_pred, aes(x = humans_eaten, y = size)) + geom_line(aes(group = sim),  
  linewidth = 0.1) + geom_hline(yintercept = 0, linetype = "dashed") +  
  geom_point(aes(group = NULL), colour = "#3333B3", data = Alien)
```




- Các phân phối tiên nghiệm cho điểm cắt trục y và độ dốc có vẻ ổn: đủ rộng để bao quát một phạm vi rộng các mối quan hệ và không quá rộng
- việc chuẩn hóa dữ liệu sẽ giúp cải thiện kết quả (xem phần sau)

LM — Phù hợp mô hình: Kiểm tra dự đoán trước

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Trước khi ước lượng mô hình, hãy đảm bảo rằng các phân phối tiên nghiệm của chúng ta không quá mơ hồ

```
ggplot() +  
  geom_histogram(aes(x = resp, after_stat(density), fill = "from priors"), data = prior_pred)  
  +  
  geom_histogram(aes(x = size, after_stat(density), fill = "observed"), alpha = 0.5, data =  
    Alien) +  
  scale_fill_manual(values = c("#00CC99", "#3333B3"), name = "data")
```



- các giá trị a priori cho sigma cũng có vẻ ổn: có khả năng các giá trị a priori này có thể tạo ra dữ liệu bao quát các giá trị thực, mà không có nguy cơ tạo ra các kích thước kỳ lạ vô lý

LM — Phù hợp mô hình: Kiểm tra dự đoán trước

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Trước khi ước lượng mô hình, hãy đảm bảo rằng các phân phối tiên nghiệm của chúng ta không quá mơ hồ


```
ggplot() +  
  geom_histogram(aes(x = resp, after_stat(density), fill = "from priors"), data = prior_pred)  
  +  
  geom_histogram(aes(x = size, after_stat(density), fill = "observed"), alpha = 0.5, data =  
    Alien) +  
  scale_fill_manual(values = c("#00CC99", "#3333B3"), name = "data")
```

Lưu ý:

- không nên tinh chỉnh các phân phối tiên nghiệm dựa trên dữ liệu quan sát vì tập dữ liệu có thể bị sai lệch (nguy cơ *quá khớp*), nhưng cần đảm bảo rằng các phân phối tiên nghiệm phải tương đối thực tế
- cách chọn các phân phối tiên nghiệm tốt nhất vẫn là một vấn đề nghiên cứu đang diễn ra, và

chủ đề được đề cập nhiều nhất trong thống kê Bayes (ví dụ: các kỹ thuật và cơ sở dữ liệu khách quan hơn đang bắt đầu xuất hiện)

- nếu bạn có đủ dữ liệu, và miễn là các phân phối a priori không quá phi lý, thì chúng sẽ ít ảnh hưởng đến các phân phối hậu nghiệm của bạn (và bạn có thể kiểm tra điều đó)



- Dù bạn làm gì, hãy mô tả rõ những gì bạn làm trong bài báo của mình!

LM — Phù hợp mô hình: Kiểm tra dự đoán trước

- các phân phối tiên nghiệm cho sigma cũng có vẻ ổn; về mặt lý thuyết, các phân phối tiên nghiệm này có thể là giả sử hợp lý để kiểm tra các giá trị thực, mà không có nguy cơ là quá lạc quan
- Trong thống kê Bayes, việc ước lượng mô hình có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm


Trước khi ước lượng mô hình, hãy đảm bảo rằng các phân phối tiên nghiệm của chúng ta không quá mơ hồ

LM — Phù hợp mô hình: Phương pháp Bayes với {nimble}

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Giờ đây, chúng ta có thể ước lượng mô hình bằng {nimble}

```
fit_alien_lm_nimb <- nimbleMCMC(code = code,  
                                constants = constants,  
                                data = list(size = Alien$size), # biến phản hồi được đặt ở đây inits  
                                = inits, nchains = 4, setSeed = 1:4,  
                                nburnin = 4000) # ở đây là đủ (brms sử dụng 1000)  
mcmc_trace(fit_alien_lm_nimb) # không phải mcmc_plot, vì hàm này chỉ dành cho {brms}
```




LM — Phù hợp mô hình: Phương pháp Bayes với {nimble}

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Dưới đây là các phân phối hậu nghiệm

```
mcmc_dens_overlay(fit_alien_lm_nimb)
```



LM — Phù hợp mô hình: Phương pháp Bayes với {nimble}

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Dưới đây là tóm tắt về các phân phối hậu nghiệm

```
fit_alien_lm_nimb_d <- as_draws(fit_alien_lm_nimb) summary(fit_alien_lm_nimb_d)
```

Một bảng: 3 x 10

biến	trung bình	trung vị	độ lệch chuẩn	mad	q5	q95	rhat	ess_bulk	ess_tail
<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 điểm cắt	49,0	49,0	1,47	1,41	46,6	51,4	1,00	2118,	3661.
2 sigma	2,00	1,90	0,519	0,441	1,36	3,00	1,00	3271.	3647.
3 độ dốc	2,29	2,29	0,685	0,657	1,19	3,41	1,00	2113.	3819.

LM — Phù hợp mô hình: Kiểm tra dự đoán a posteriori

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Sau khi ước lượng mô hình, hãy đảm bảo rằng phân phối a posteriori của chúng ta không sai lệch

```
posterior1 <- tibble(
  intercept = fit_alien_lm_nimb_d[, 1, "intercept", drop = TRUE], slope =
  fit_alien_lm_nimb_d[, 1, "slope", drop = TRUE],
  sigma = fit_alien_lm_nimb_d[, 1, "sigma", drop = TRUE])

expand_grid(posterior1, humans_eaten = Alien$humans_eaten) |> mutate(error =
  rnorm(n = n(), mean = 0, sd = sigma),
  pred = intercept + slope * humans_eaten + error) -> pred1

ggplot() +
  geom_density(aes(x = pred, after_stat(density),
    colour = "from posteriors"), data = pred1) +
  geom_density(aes(x = resp, after_stat(density),
    colour = "from priors"), data = prior_pred,) +
  geom_density(aes(x = size, after_stat(density),
    colour = "observed"), data = Alien) + scale_colour_manual(values =
  c("#FF5050", "#00CC99", "#3333B3"),
    name = "data",
    guide = guide_legend(position = "top")) + xlim(limits =
  c(35, 75))
```

LM — Phù hợp mô hình: Kiểm tra dự đoán a posteriori


- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Sau khi ước lượng mô hình, hãy đảm bảo rằng phân phối a posteriori của chúng ta không sai lệch

```
posterior1 <- tibble(
  intercept = fit_alien_lm_nimb_d[, 1, "intercept", drop = TRUE], slope =
  fit_alien_lm_nimb_d[, 1, "slope", drop = TRUE],
  sigma = fit_alien_lm_nimb_d[, 1, "sigma", drop = TRUE])

expand_grid(posterior1, humans_eaten = Alien$humans_eaten) |> mutate(error = rnorm(n
  = n()), mean = 0, sd = sigma),
  pred = intercept + slope * humans_eaten + error) -> pred1

ggplot() +
  geom_density(aes(x = pred, after_stat(density),
    colour = "from posteriors"), data = pred1) +
  geom_density(aes(x = resp, after_stat(density),
    colour = "from priors"), data = prior_pred,) +
  geom_density(aes(x = size, after_stat(density),
    colour = "quan sát"), data = Alien) +
  scale_colour_manual(values = c("#FF5050", "#00CC99", "#3333B3"),
    tên = "data",
    hướng dẫn = guide_legend(vị trí = "top")) + xlim(giới
  hạn = c(35, 75))
```




- trông có vẻ ổn: các dự đoán hậu nghiệm tập trung hơn nhiều so với các dự đoán tiên nghiệm, và gần với các quan sát

LM — Phù hợp mô hình: Kiểm tra dự đoán a posteriori

- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Hãy kiểm tra mức độ tương quan giữa các phân phối hậu nghiệm

```
ggplot() +  
  geom_point(aes(y = intercept, x = slope, colour = "prior"), alpha = 0.3, data  
              = prior) +  
  geom_point(aes(y = intercept, x = slope, colour = "posterior"),  
              alpha = 0.3, data = posterior1) +  
  scale_colour_manual(  
    values = c("#00CC99", "#FF5050"),  
    tên = "data",  
    hướng dẫn = guide_legend(vị trí = "trên",  
                              override.aes = list(alpha = 1)))
```



- Điều này có vẻ ổn: các dự đoán sau nằm trong phạm vi của các phân phối tiên nghiệm, điều này càng khẳng định sự lựa chọn các phân phối tiên nghiệm của chúng ta

LM — Phù hợp mô hình: Kiểm tra dự đoán a posteriori


- Trong thống kê Bayes, *việc ước lượng mô hình* có nghĩa là sử dụng dữ liệu để mô tả các phân phối hậu nghiệm

Hãy kiểm tra mức độ tương quan giữa các phân phối hậu nghiệm

```
ggplot() +  
  geom_point(aes(y = intercept, x = slope, colour = "prior"), alpha = 0.3, data  
              = prior) +  
  geom_point(aes(y = intercept, x = slope, colour = "posterior"),  
              alpha = 0.3, data = posterior1) +  
  scale_colour_manual(  
    values = c("#00CC99", "#FF5050"),  
    tên = "data",  
    hướng dẫn = guide_legend(vị trí = "trên",  
                              override.aes = list(alpha = 1)))
```

Lưu ý: đối với các ứng dụng thực tế

- các biến dự báo nên được chuẩn hóa để tránh các mối tương quan mạnh (xem phần sau)



- Điều này có vẻ ổn: các dự đoán sau nằm trong phạm vi của các phân phối tiên nghiệm, điều này càng khẳng định sự lựa chọn các phân phối tiên nghiệm của chúng ta

LM — Kết quả vừa khít mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

`lm()`

Một bảng: 3 x 5

Tham số	Ước lượng	Độ lệch chuẩn	2,5 %	97,5 %
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 (Hằng số)	48,8	1,35	45,8	51,8
2 người bị ăn thịt	2,37	0,623	0,987	3,76
3 sigma	1,76	1,39	1,01	6,36

`brms::brm()`

Một bảng: 3 x 5

Tham số	Ước lượng	Sai số ước lượng	Q2,5	Q97,5
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 Hằng số	48,8	1,51	45,8	51,8
2 người bị ăn thịt	2,38	0,700	0,993	3,76
3 sigma	1,92	0,463	1,26	3,03

`nimble::nimbleMCMC()`

Một bảng: 3 x 5

biến	trung bình	độ lệch chuẩn	2,5%	97,5%
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 hằng số	49,0	1,47	46,1	51,9
2 độ dốc	2,29	0,685	0,949	3,65
3 sigma	2,00	0,519	1,28	3,32

LM — Kết quả vừa khít mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

`lm()`

```
# Một bảng: 3 x 5
  Tham số      Ước lượng `Độ lệch chuẩn` `2,5 %` `97,5 %`
<chr>          <dbl>          <dbl>    <dbl>    <dbl>
1 (Hằng số)    48,8          1,35    45,8    51,8
2 người bị ăn thịt  2,37        0,623    0,987    3,76
3 sigma        1,76          1,39    1,01    6,36
```

`brms::brm()`

```
# Một bảng: 3 x 5
  Tham số      Ước lượng Sai số ước lượng Q2,5 Q97,5
<chr>          <dbl>    <dbl> <dbl> <dbl>
1 Hằng số    48,8      1,51 45,8    51,8
2 người bị ăn thịt  2,38    0,700 0,993 3,76
3 sigma      1,92    0,463 1,26    3,03
```

`nimble::nimbleMCMC()`

```
# Một bảng: 3 x 5
  biến      trung bình độ lệch chuẩn `2,5%` `97,5%`
<chr>      <dbl> <dbl> <dbl>    <dbl>
1 hằng số  49,0  1,47 46,1    51,9
2 độ dốc   2,29 0,685 0,949    3,65
3 sigma    2,00 0,519 1,28    3,32
```

- mặc dù kích thước mẫu nhỏ (N=12) nhưng các ước lượng đều nhất quán và tất cả các khoảng tin cậy đều bao gồm các giá trị thực

LM — Kết quả vừa khít mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

`lm()`

Một bảng: 3 x 5

Tham số	Ước lượng	Độ lệch chuẩn	2,5 %	97,5 %
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 (Hằng số)	48,8	1,35	45,8	51,8
2 người bị ăn thịt	2,37	0,623	0,987	3,76
3 sigma	1,76	1,39	1,01	6,36

`brms::brm()`

Một bảng: 3 x 5

Tham số	Ước lượng	Sai số	Ước lượng	Q2,5	Q97,5
<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 Hằng số	48,8	1,51	45,8		51,8
2 người bị ăn thịt	2,38	0,700	0,993		3,76
3 sigma	1,92	0,463	1,26		3,03

`nimble::nimbleMCMC()`

Một bảng: 3 x 5

biến	trung bình	độ lệch chuẩn	2,5%	97,5%
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 hằng số	49,0	1,47	46,1	51,9
2 độ dốc	2,29	0,685	0,949	3,65
3 sigma	2,00	0,519	1,28	3,32

- mặc dù cỡ mẫu nhỏ (N=12) nhưng các ước lượng đều nhất quán và tất cả các khoảng tin cậy đều bao gồm các giá trị thực
- chúng tôi chưa bao giờ thu được các giá trị 50 (hằng số cắt), 1,5 (hệ số dốc) hoặc 2 (sigma) vì một mẫu hiếm khi phản ánh hoàn hảo các giá trị ở cấp độ dân số; chỉ khi $N=\infty$ hoặc "nói chuyện với nữ thần" thì mới có thể đạt được những giá trị đó

LM — Kết quả vừa khít mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

`lm()`

Một bảng: 3 x 5

Tham số <chr>	Ước lượng <dbl>	Độ lệch chuẩn <dbl>	2,5 % <dbl>	97,5 % <dbl>
1 (Hằng số)	48,8	1,35	45,8	51,8
2 người bị ăn thịt	2,37	0,623	0,987	3,76
3 sigma	1,76	1,39	1,01	6,36

`brms::brm()`

Một bảng: 3 x 5

Tham số Q97,5 <chr>	Giá trị ước lượng <dbl>	Sai số ước lượng <dbl>	Q2,5 <dbl>	Q97,5 <dbl>
1 Hằng số	48,8	1,51	45,8	51,8
2 người bị ăn thịt	2,38	0,700	0,993	3,76
3 sigma	1,92	0,463	1,26	3,03

`nimble::nimbleMCMC()`

Một bảng: 3 x 5

biến <chr>	trung bình <dbl>	độ lệch chuẩn <dbl>	2,5% <dbl>	97,5% <dbl>
1 hằng số	49,0	1,47	46,1	51,9
2 độ dốc	2,29	0,685	0,949	3,65
3 sigma	2,00	0,519	1,28	3,32

- mặc dù kích thước mẫu nhỏ (N=12) nhưng các ước lượng đều nhất quán và tất cả các khoảng tin cậy đều bao gồm các giá trị thực
- chúng tôi chưa bao giờ thu được các giá trị 50 (hằng số cắt), 1,5 (hệ số dốc) hoặc 2 (sigma) vì một mẫu hiếm khi phản ánh hoàn hảo các giá trị ở cấp độ dân số; chỉ khi $N=\infty$ hoặc trò chuyện với nữ thần thì bạn mới có thể có được những giá trị đó

Ghi chú chuyên sâu:

- trong hàm `lm()`, σ thường không phải là tham số được ước lượng trực tiếp, mà được suy ra sau khi đã ước lượng được hằng số cắt và độ dốc (trong quá trình tính toán, tôi đã gặp khó khăn khi tính độ lệch chuẩn (SE) và khoảng tin cậy (CI) cho nó)

LM — Kết quả vừa khít mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

lm()

Một bảng: 3 x 5

Tham số <chr>	Giá trị ước lượng <dbl>	Độ lệch chuẩn <dbl>	2,5 % <dbl>	97,5 % <dbl>
1 (Hằng số)	48,8	1,35	45,8	51,8
2 người bị ăn thịt	2,37	0,623	0,987	3,76
3 sigma	1,76	1,39	1,01	6,36

brms::brm()

Một bảng: 3 x 5

Tham số <chr>	Ước lượng <dbl>	Sai số <dbl>	ước lượng <dbl>	Q2,5 <dbl>	Q97,5 <dbl>
1 Hằng số	48,8	1,51	45,8		51,8
2 người bị ăn thịt	2,38	0,700	0,993	3,76	
3 sigma	1,92	0,463	1,26		3,03

nimble::nimbleMCMC()

Một bảng: 3 x 5

biến <chr>	trung bình <dbl>	độ lệch <dbl>	chuẩn <dbl>	2,5% <dbl>	97,5% <dbl>
1 hằng số	49,0	1,47	46,1		51,9
2 độ dốc	2,29	0,685	0,949		3,65
3 sigma	2,00	0,519	1,28		3,32

- Mặc dù quy mô mẫu nhỏ ($N=12$), các ước lượng vẫn nhất quán với nhau và tất cả các khoảng tin cậy đều bao gồm các giá trị thực
- chúng tôi chưa bao giờ thu được các giá trị 50 (hằng số cắt), 1,5 (hệ số dốc) hay 2 (độ lệch chuẩn) vì một mẫu hiếm khi phản ánh hoàn hảo các giá trị ở cấp độ tổng thể; chỉ khi $N=\infty$ hoặc trò chuyện với nữ thần thì bạn mới có thể có được những giá trị đó

Ghi chú chuyên sâu:

- Trong hàm `lm()`, σ thường không phải là tham số được ước lượng trực tiếp, mà được suy ra sau khi đã ước lượng được hằng số cắt và độ dốc (trong quá trình tính toán, tôi đã gặp khó khăn khi tính toán độ lệch chuẩn (SE) và khoảng tin cậy (CI) cho nó)
- theo mặc định, nimble trả về q5 và q95 (chứ không phải q2.5 và q97.5), vì vậy tôi phải yêu cầu điều này thủ công (xem `?summarise_draws`)

Bài tập 2

1. Khám phá tập dữ liệu `penguins` (có sẵn trong R)
2. hãy kiểm tra tài liệu hướng dẫn của nó bằng lệnh `?penguins`
3. sử dụng tập dữ liệu này, ước lượng mô hình tuyến tính với:
`body_mass` làm biến phụ thuộc
 - `flipper_len` là các biến độc lập

Giải thích các hệ số

Giải thích các hệ số — phần giới thiệu

Việc giải thích đúng ý nghĩa của *các hệ số hồi quy* (= *ước lượng tham số*) trong các mô hình thống kê là phần quan trọng nhất, bởi vì:

- các hệ số đóng vai trò trung gian trong mối quan hệ giữa các số liệu thống kê và sinh học

Giải thích các hệ số — phần giới thiệu

Việc giải thích đúng ý nghĩa của *các hệ số hồi quy* (= *ước lượng tham số*) trong các mô hình thống kê là phần quan trọng nhất, bởi vì:

- các hệ số đóng vai trò trung gian trong mối quan hệ giữa các số liệu thống kê và sinh học
- các kiểm định, độ lệch chuẩn (SE), khoảng tin cậy và khoảng dự đoán, tất cả đều tập trung vào các hệ số này

Giải thích các hệ số — phần giới thiệu

Việc giải thích chính xác ý nghĩa của *các hệ số hồi quy* (= *ước lượng tham số*) trong các mô hình thống kê là phần quan trọng nhất vì:

- các hệ số đóng vai trò trung gian trong mối quan hệ giữa các số liệu thống kê và sinh học
- các bài kiểm định, độ lệch chuẩn (SE), khoảng tin cậy và khoảng dự đoán đều tập trung vào các hệ số
- này các phần mềm và gói phần mềm khác nhau có thể ảnh hưởng đến các khía cạnh (so sánh, thang đo) tác động đến ý nghĩa của các hệ số

Giải thích các hệ số — phần giới thiệu

Việc giải thích đúng ý nghĩa của *các hệ số hồi quy* (= *ước lượng tham số*) trong các mô hình thống kê là phần quan trọng nhất, bởi vì:

các hệ số đóng vai trò trung gian trong mối quan hệ giữa thống kê và sinh học

- các bài kiểm định, độ lệch chuẩn (SE), khoảng tin cậy và khoảng dự đoán đều tập trung vào các hệ số
- này các phần mềm và gói phần mềm khác nhau có thể ảnh hưởng đến các khía cạnh (so sánh, thang đo) tác động đến ý nghĩa của các hệ số
- hầu hết các nhà khoa học không thực hiện điều này một cách chính xác, làm ảnh hưởng đến các kết luận được đưa ra trong nhiều công bố

Giải thích các hệ số — phần giới thiệu

Việc giải thích đúng ý nghĩa của *các hệ số hồi quy* (= *ước lượng tham số*) trong các mô hình thống kê là phần quan trọng nhất, bởi vì:

các hệ số đóng vai trò trung gian trong mối quan hệ giữa thống kê và sinh học

- các bài kiểm định, độ lệch chuẩn (SE), khoảng tin cậy và khoảng dự đoán đều tập trung vào các hệ số
- này các phần mềm và gói phần mềm khác nhau có thể ảnh hưởng đến các khía cạnh (so sánh, thang đo) tác động đến ý nghĩa của các hệ số
- hầu hết các nhà khoa học không thực hiện đúng cách, làm ảnh hưởng đến các kết luận được đưa ra trong nhiều công bố

Lưu ý:

- việc này đòi hỏi một chút tập trung, nhưng không cần kiến thức toán học cao hơn trình độ trung học cơ sở

Giải thích các hệ số — Chuẩn bị dữ liệu: Làm sạch dữ liệu

Hãy tạo một bộ dữ liệu duy nhất và gọn gàng với tất cả các biến mà chúng ta sẽ cần cho tất cả các mô hình

```
penguins |> as_tibble() |>
  select(-starts_with("bill")) |>
  drop_na() |>
  mutate(flipper_len_z = scale(flipper_len)[,1], .after = flipper_len) |> mutate(body_mass_z =
  scale(body_mass)[,1], .after = body_mass) -> penguins_clean

penguins_clean
```

Một tibble: 333 x 8


loài	đảo	chiều_dài_vây	chiều_dài_vây_z	khối_lượng	khối_lượng_z	giới_tính	year
<fct>	<fct>	<int>	<dbl>	<int>	<dbl>	<fct>	<int>
1	Adelie Torgersen	181	-1,42	3750	-0,568	nam	2007
2	Adelie Torgersen	186	-1,07	3.800	-0,506	nữ	2007
3	Adelie Torgersen	195	-0,426	3250	-1,19	nữ	2007
4	Adelie Torgersen	193	-0,568	3.450	-0,940	nữ	2007
5	Adelie Torgersen	190	-0,782	3650	-0,692	nam	2007

i 328 hàng nữa

Lưu ý: hàm `scale()` tạo ra các điểm z (nó loại bỏ giá trị trung bình và chia cho độ lệch chuẩn)

Giải thích các hệ số — Chuẩn bị dữ liệu: Biểu đồ

```
ggplot(penguins_clean) +  
  aes(y = khối_lượng, x = chiều_dài_vây, màu = loài, hình = giới_tính) + geom_point(alpha =  
  0.5) +  
  labs(y = "Khối lượng cơ thể (gr)", x = "Chiều dài vây (mm)")
```



Giải thích các hệ số — hệ số cắt và hệ số dốc

Làm thế nào để giải thích các hệ số hồi quy?

```
fit_flipper <- lm(body_mass ~ flipper_len, data = penguins_clean)
coef(fit_flipper)
```

(Hằng số cắt) flipper_len
-5872,09268 50,15327

Giải thích các hệ số — hệ số cắt và hệ số dốc

Làm thế nào để giải thích các hệ số hồi quy?

```
fit_flipper <- lm(body_mass ~ flipper_len, data = penguins_clean)
coef(fit_flipper)
```

(Điểm cắt) flipper_len
-5872,09268 50,15327

- *Hằng số cắt* là giá trị dự đoán khi tất cả các biến giải thích đều bằng 0, do đó ở đây nó tương ứng với khối lượng cơ thể trung bình của một con chim cánh cụt không có vây (tức là một *phép ngoại suy* vô nghĩa trong trường hợp này)

```
predict(fit_flipper, newdata = tibble(flipper_len = 0))
```

1
-5872,093

Giải thích các hệ số — hệ số cắt và hệ số dốc

Làm thế nào để giải thích các hệ số hồi quy?

```
fit_flipper <- lm(body_mass ~ flipper_len, data = penguins_clean) coef(fit_flipper)
```

```
(Hàng số) flipper_len  
-5872,09268      50,15327
```

- **độ dốc** cho biết sự thay đổi của các giá trị dự đoán khi biến giải thích liên quan tăng thêm 1 đơn vị, vì vậy ở đây điều này có nghĩa là mô hình dự đoán rằng những con chim cánh cụt có vây dài hơn 1mm so với những con khác thì trung bình nặng hơn 50gr so với những con đó

```
pred_diff <- predict(fit_flipper, newdata = tibble(flipper_len = c(200, 201))) pred_diff
```

```
      1      2  
4158,561 4208,714
```

```
pred_diff[2] - pred_diff[1] # hoặc đơn giản là diff(pred_diff)
```

```
      2  
50,15327
```

Giải thích các hệ số — chuẩn hóa các biến độc lập

Làm thế nào để giải thích các hệ số hồi quy khi các biến độc lập được chuẩn hóa?

```
fit_flipper_z <- lm(body_mass ~ flipper_len_z, data = penguins_clean)
coef(fit_flipper_z)
```

(Hàng số) flipper_len_z
4207,0571 702,9364

Giải thích các hệ số — chuẩn hóa các biến độc lập

Làm thế nào để giải thích các hệ số hồi quy khi các biến độc lập được chuẩn hóa?

```
fit_flipper_z <- lm(body_mass ~ flipper_len_z, data = penguins_clean)
coef(fit_flipper_z)
```

```
(Hàng số) flipper_len_z
4207,0571      702,9364
```

Lưu ý:

- Chuẩn hóa* có nghĩa là loại bỏ giá trị trung bình (tức là *căn giữa*) và chia cho độ lệch chuẩn (tức là *chuẩn hóa*). Việc chuẩn hóa cả biến phụ thuộc và các biến độc lập là một thực hành được khuyến nghị khi sử dụng {nimble}, {stan}, v.v... vì điều này giúp định nghĩa các phân phối a priori nhất quán hơn giữa các nghiên cứu; đồng thời cũng cải thiện hiệu quả của một số thuật toán lấy mẫu MCMC do giảm bớt sự tương quan giữa các phân phối a posteriori
- một số gói phần mềm thực hiện các thao tác tương tự bên trong (ví dụ: {brms}), đồng thời tự thực hiện phép *biến đổi ngược* cần thiết để cho phép diễn giải ở các thang đo ban đầu

Giải thích các hệ số — chuẩn hóa các biến độc lập

Làm thế nào để giải thích các hệ số hồi quy khi các biến độc lập được chuẩn hóa?

```
fit_flipper_z <- lm(body_mass ~ flipper_len_z, data = penguins_clean)
coef(fit_flipper_z)
```

(Hàng số cắt) flipper_len_z
4207,0571 702,9364

- *Hàng số cắt* vẫn là giá trị dự đoán khi tất cả các biến giải thích đều bằng 0, nhưng `flipper_len = 0` có nghĩa là chiều dài vây là 0 mm, trong khi `flipper_len_z = 0` có nghĩa là chiều dài vây trung bình; do đó, ở đây hàng số cắt tương ứng với khối lượng cơ thể trung bình của một con chim cánh cụt có chiều dài vây là 201 mm (tức là không còn vô nghĩa nữa)

Giải thích các hệ số — chuẩn hóa các biến độc lập

Làm thế nào để giải thích các hệ số hồi quy khi các biến độc lập được chuẩn hóa?

```
fit_flipper_z <- lm(body_mass ~ flipper_len_z, data = penguins_clean)
coef(fit_flipper_z)
```

```
(Hàng số cắt) flipper_len_z
4207,0571      702,9364
```

- **độ dốc** vẫn là sự thay đổi trong các giá trị dự đoán khi biến hồi quy liên quan tăng thêm 1 đơn vị, nhưng ở đây 1 đơn vị không còn là 1 mm mà là 1 độ lệch chuẩn về chiều dài vây; do đó, ở đây điều này có nghĩa là mô hình dự đoán rằng những con chim cánh cụt có vây dài hơn 1 độ lệch chuẩn so với những con khác (14 mm) thì trung bình nặng hơn 703 gr so với những con khác

biến đổi ngược

Có thể chuyển đổi các hệ số để quay trở lại thang đo ban đầu (chưa được chuyển đổi)!

```
coef(fit_flipper_z)["flipper_len_z"] / sd(penguins_clean$flipper_len)
```

```
flipper_len_z
50,15327
```

Giải thích các hệ số — quy đổi phản ứng

Làm thế nào để giải thích các hệ số hồi quy khi biến phụ thuộc được quy mô hóa?

```
fit_flipper_bmz <- lm(body_mass_z ~ flipper_len, data = penguins_clean) coef(fit_flipper_bmz)
```

(Hàng số) flipper_len
-12.5173273 0,0622855

- Một lần nữa, **hằng số cắt** vẫn là giá trị dự đoán khi tất cả các biến độc lập đều bằng 0, và hệ **số góc** vẫn là sự thay đổi của các giá trị dự đoán khi biến độc lập tương ứng tăng thêm 1 đơn vị; tuy nhiên, lần này các giá trị dự đoán được biểu thị bằng số độ lệch chuẩn (SD) so với giá trị trung bình (tức là điểm z) thay vì gam

biến đổi ngược

```
coef(fit_flipper_bmz)["(Hàng số)"] * sd(penguins_clean$body_mass) + mean(penguins_clean$body_mass)
```

(Hàng số)
-5872,093

```
coef(fit_flipper_bmz)["flipper_len"] * sd(penguins_clean$body_mass)
```

flipper_len

50 . 15 32 7

Bài tập 3

Làm thế nào để giải thích các hệ số hồi quy khi biến phụ thuộc và các biến độc lập được chuẩn hóa?

```
fit_flipper_zz <- lm(body_mass_z ~ flipper_len_z, data = penguins_clean) coef(fit_flipper_zz)
```

(Hằng số) flipper_len_z
-2.689131e-16 8.729789e-01

1. giải thích hệ số dốc trên thang đo mới
2. giải thích hằng số cắt trên thang đo mới
3. Áp dụng phép biến đổi ngược cần thiết để thực hiện việc giải thích hệ số góc trên thang đo ban đầu
4. Hãy suy nghĩ về cách bạn sẽ định nghĩa các phân phối tiên nghiệm trong trường hợp này

Giải pháp

Làm thế nào để giải thích các hệ số hồi quy khi biến phụ thuộc và các biến độc lập được quy đổi?

```
fit_flipper_zz <- lm(body_mass_z ~ flipper_len_z, data = penguins_clean) coef(fit_flipper_zz)
```

(Hằng số) flipper_len_z
-2.689131e-16 8.729789e-01

1. độ dốc mô tả sự gia tăng độ lệch chuẩn (SD) của khối lượng cơ thể khi chiều dài vây tăng thêm 1 SD
2. hằng số cắt là giá trị trung bình của điểm z khối lượng cơ thể đối với một con chim cánh cụt có chiều dài vây trung bình, đó là lý do tại sao nó bằng 0 (một nhóm chim cánh cụt có chiều dài vây trung bình được dự kiến sẽ có khối lượng cơ thể trung bình)
3. biến đổi ngược của hệ số góc:

```
(coef(fit_flipper_zz)["flipper_len_z"] / sd(penguins_clean$flipper_len)) * sd(penguins_clean$body_mass)
```

flipper_len_z
50,15327

Giải pháp

4. một giá trị nào đó $\mathcal{N}(0, \sigma = 2)$ cho cả phân phối tiên nghiệm của hằng số cắt và độ dốc đều có vẻ phù hợp (và gần với cài đặt mặc định của {brms})


```
set.seed(123)
n_sims <- 100

prior <- tibble(sim = seq_len(n_sims),
  intercept = rnorm(n_sims, mean = 0, sd = 2), slope =
  rnorm(n_sims, mean = 0, sd = 2))

flipper_len_z_possible <- -3:3

expand_grid(prior, flipper_len_z = flipper_len_z_possible) |> mutate(
  body_mass_z = intercept[sim] + slope[sim]*flipper_len_z) -> prior_pred

ggplot(prior_pred, aes(flipper_len_z, body_mass_z)) +
  geom_line(aes(group = sim), linewidth = 0.1) + geom_hline(yintercept
= 0, linetype = "dashed") + geom_point(aes(group = NULL), data =
penguins_clean)
```



Giải thích các hệ số — các biến độc lập định tính

Làm thế nào để giải thích các hệ số hồi quy?

```
fit_sex <- lm(body_mass ~ sex, data = penguins_clean) coef(fit_sex)
```

(Điểm cắt trực y)

	giới_tính_
nam	3862.2727
	683,4118

Giải thích các hệ số — các biến độc lập định tính

Làm thế nào để giải thích các hệ số hồi quy?

```
fit_sex <- lm(body_mass ~ sex, data = penguins_clean) coef(fit_sex)
```

(Intercept)	nam
3862.2727	683,4118

Có ý kiến gì không?

Giải thích các hệ số — các biến độc lập định tính

Làm thế nào để giải thích các hệ số hồi quy?

```
fit_sex <- lm(body_mass ~ sex, data = penguins_clean) coef(fit_sex)
```

(Intercept)	nam
3862.2727	683,4118

Có ý kiến gì không?

Lưu ý: trong bối cảnh này, tốt nhất là nên tránh đoán mò

Giải thích các hệ số — Phần giải thích về ma trận mô hình

Sẽ hữu ích hơn nếu kiểm tra cách dữ liệu được chuyển đổi thành *ma trận mô hình*:

```
penguins_clean # dữ liệu
```

```
# Một bảng: 333 x 8
```

	loài đảo	chiều dài vây	chiều dài vây_z	khối lượng cơ thể	khối lượng cơ thể_z	giới tính	năm
	<fct>	<fct>	<int>	<dbl>	<int>	<dbl> <fct>	<int>
1	Adelie Torgersen	181	-1,42	3750	-0,568	nam	2007
2	Adelie Torgersen	186	-1,07	3.800	-0,506	nữ	2007
3	Adelie Torgersen	195	-0,426	3.250	-1,19	nữ	2007
4	Adelie Torgersen	193	-0,568	3.450	-0,940	nữ	2007
5	Adelie Torgersen	190	-0,782	3.650	-0,692	nam	2007

```
# i 328 hàng nữa
```

```
head(model.matrix(fit_sex))
```

(Hàng số) sexmale

1	1	1
2	1	0
3	1	0
4	1	0
5	1	1
6	1	0

Giải thích các hệ số — Phần giải thích về ma trận mô hình

Sẽ hữu ích hơn nếu kiểm tra cách dữ liệu được chuyển đổi thành *ma trận mô hình*:

```
penguins_clean # dữ liệu
```

```
# Một bảng: 333 x 8
```

loài đảo	chiều dài vây	chiều dài vây_z	khối lượng cơ thể	khối lượng cơ thể_z	giới tính	năm
<fct>	<fct>	<int>	<dbl>	<int>	<dbl>	<fct>
1 Adelie Torgersen	181	-1,42	3750	-0,568	nam	2007
2 Adelie Torgersen	186	-1,07	3.800	-0,506	nữ	2007
3 Adelie Torgersen	195	-0,426	3250	-1,19	nữ	2007
4 Adelie Torgersen	193	-0,568	3.450	-0,940	nữ	2007
5 Adelie Torgersen	190	-0,782	3650	-0,692	nam	2007

```
# i 328 hàng nữa
```

```
head(model.matrix(fit_sex))
```

(Hàng số) sexmale

1	1	1
2	1	0
3	1	0
4	1	0
5	1	1
6	1	0

- Ma trận mô hình được nhân với các hệ số hồi quy, do đó hệ số sexmale được nhân với 1 khi hàng tương ứng với nam giới, và nhân với 0 khi tương ứng với nữ giới

Giải thích các hệ số — Phần giải thích về ma trận mô hình

Sẽ hữu ích hơn nếu kiểm tra cách dữ liệu được chuyển đổi thành *ma trận mô hình*:

```
penguins_clean # dữ liệu
```

```
# Một bảng: 333 x 8
```

	loài đảo	flipper_len	flipper_len_z	body_mass	body_mass_z	sex	year	
	<fct>	<fct>	<int>	<dbl>	<int>	<dbl>	<fct>	<int>
1	Adelie	Torgersen	181	-1,42	3750	-0,568	nam	2007
2	Adelie	Torgersen	186	-1,07	3.800	-0,506	nữ	2007
3	Adelie	Torgersen	195	-0,426	3250	-1,19	nữ	2007
4	Adelie	Torgersen	193	-0,568	3.450	-0,940	nữ	2007
5	Adelie	Torgersen	190	-0,782	3650	-0,692	nam	2007

```
# i 328 hàng nữa
```

```
head(model.matrix(fit_sex))
```

(Hàng số) sexmale

1	1	1
2	1	0
3	1	0
4	1	0
5	1	1
6	1	0

- Ma trận mô hình được nhân với các hệ số hồi quy, do đó hệ số sexmale được nhân với 1 khi hàng tương ứng với nam giới, và nhân với 0 khi tương ứng với nữ giới
- theo mặc định, R chọn một mức tham chiếu (theo mặc định là mức đầu tiên theo thứ tự bảng chữ cái) và biểu diễn các hiệu ứng khác so với mức tham chiếu đó, một phương pháp được gọi là *so sánh điều trị*

Giải thích các hệ số — các biến độc lập định tính

Làm thế nào để giải thích các hệ số hồi quy?

```
coef(fit_sex)
```

	(Hằng số)	giới_tính
nam	3862,2727	683,4118

giá trị dự đoán_i = (Hằng số) × 1 + sexmale × (0 nếu_i là nữ hoặc 1 nếu_i là nam)

- **hằng số** vẫn là giá trị dự đoán khi tất cả các biến độc lập đều bằng 0, do đó ở đây khối lượng cơ thể trung bình của một con chim cánh cụt **cái**
- giá trị được gọi là **sexmale** cho biết mức độ tăng của các giá trị dự đoán khi cột của ma trận thiết kế có tên **sexmale** thay đổi từ 0 sang 1 → do đó, đây là mức tăng trung bình về khối lượng cơ thể của chim cánh cụt đực **so với** chim cánh cụt cái

Khi còn nghi ngờ, hãy so sánh các dự đoán!

```
pred_sex <- predict(fit_sex, newdata = tibble(sex = c("female", "male"))) pred_sex
```

1	2
3862,273	4545,685

Bài tập 4

Làm thế nào để giải thích các hệ số hồi quy có tương tác giữa một biến độc lập định tính và một biến độc lập định lượng?

```
fit_flipper_int <- lm(body_mass ~ flipper_len*sex, data = penguins_clean) coef(fit_flipper_int)
```

(Hằng số)	flipper_len	giới_tính nam	chiều_dài_vây:giới_tính_nam
-5443,9607499	47,1527260	406,8015395	-0,2942184

1. Kiểm tra ma trận thiết kế để hiểu biến giải thích được sử dụng bởi `flipper_len:sexmale`
2. dự đoán thủ công:
 - khối lượng cơ thể trung bình của một con chim cánh cụt cái có chiều dài cánh 200 mm khối
 - lượng cơ thể trung bình của một con chim cánh cụt đực có chiều dài cánh 200 mm
3. giải thích ý nghĩa của cả 4 hệ số
4. Khối lượng cơ thể của chim cánh cụt đực có tăng theo chiều dài cánh không?

Giải pháp

```
coef(fit_flipper_int)
```

(Hàng số)	flipper_len	giới_tính_nam	chiều_dài_vây:giới_tính_nam
-5443,9607499	47,1527260	406,8015395	-0,2942184

1. Ma trận thiết kế cho biết `flipper_len:sexmale` bằng 0 đối với chim cánh cụt cái và chiều dài vây khi chim cánh cụt là đực

```
head(model.matrix(fit_flipper_int), n = 2)
```

	(Hàng số)	flipper_len	sexmale	flipper_len:sexmale
1	1	181	1	181
2	1	186	0	0

Một bảng: 2 x 8

loài	đảo	chiều dài vây	chiều dài vây_z	khối lượng cơ thể	khối lượng cơ thể_z	giới tính	year
<fct>	<fct>	<int>	<dbl>	<int>	<dbl>	<fct>	<int>
1	Adelie Torgersen	181	-1,42	3750	-0,568	nam	2007
2	Adelie Torgersen	186	-1,07	3.800	-0,506	nữ	2007

Giải pháp

```
coef(fit_flipper_int)
```

(Hằng số)	chiều dài vây	giới tính nam	flipper_len:sexmale
-5443,9607499	47,1527260	406,8015395	-0,2942184

2. Các dự đoán có thể được tính toán như sau:

p giá trị dự đoán_i = (Hằng số) × 1 + flipper_len × flipper_len_i + sexmale ×
(0 nếu_i là con cái hoặc 1 nếu_i là con đực) + flipper_len:sexmale × (0 nếu_i là con cái hoặc flipper_len_i nếu_i là con đực)

- khối lượng cơ thể trung bình của một con chim cánh cụt cái có chiều dài vây 200 mm

$$= -5443,96 + 47,15 \times 200 + 406,80 \times 0 - 0,29 \times 0 \sim 3986$$

Giải pháp

```
coef(fit_flipper_int)
```

(Hằng số cắt)	flipper_len	giới_tínhnam	chiều_dài_vây:giới_tính_nam
-5443,9607499	47,1527260	406,8015395	-0,2942184

2. Các dự đoán có thể được tính toán như sau:

p_i giá trị dự đoán $_i = (\text{Hằng số}) \times 1 + \text{flipper_len} \times \text{flipper_len}_i + \text{sexmale} \times$
(0 nếu i là con cái hoặc 1 nếu i là con đực) + $\text{flipper_len} : \text{sexmale} \times (0$ nếu i là con cái hoặc flipper_len_i nếu i là con đực)

- khối lượng cơ thể trung bình của một con chim cánh cụt cái có chiều dài vây là 200 mm

$$= -5443,96 + 47,15 \times 200 + 406,80 \times 0 - 0,29 \times 0 \sim 3986$$

- khối lượng cơ thể trung bình của một con chim cánh cụt đực có chiều dài cánh 200 mm

$$= -5443,96 + 47,15 \times 200 + 406,80 \times 1 - 0,29 \times 200 = 3986 \sim 4335$$

Giải pháp chính xác (không làm tròn)

```
predict(fit_flipper_int, newdata = tibble(sex = c("female", "male"), flipper_len = 200))
```

1 2

3 98 6.5 84 4 3 34 . 5 42

Giải pháp

```
coef(fit_flipper_int)
```

(Hằng số cắt)	flipper_len	giới tính nam	flipper_len:sexmale
-5443,9607499	47,1527260	406,8015395	-0,2942184

3. Giải thích

- (Hệ số cắt) = khối lượng cơ thể trung bình của các cá thể cái có vây dài 0 mm
- flipper_len = mức tăng trung bình về khối lượng cơ thể của cá cái khi chiều dài vây tăng thêm 1 mm
sexmale = mức tăng trung bình về khối lượng cơ thể của con đực so với khối lượng cơ thể của con cái đối với những con chim cánh cụt có chiều dài vây là 0 mm
- flipper_len:sexmale = mức tăng trung bình về khối lượng cơ thể của con đực so với mức tăng của con cái khi chiều dài vây tăng thêm 1 mm

Giải pháp

```
coef(fit_flipper_int)
```

(Hằng số)	flipper_len	sexmale	flipper_len:sexmale
-5443,9607499	47,1527260	406,8015395	-0,2942184

4. khối lượng cơ thể thực sự tăng theo chiều dài vây ở con đực vì ảnh hưởng của chiều dài vây ở con đực là $47,15 - 0,29 (>> 0)$


```
predict(fit_flipper_int, newdata = tibble(sex = "nam", flipper_len = c(200, 201)))
```

1	2
4334,542	4381,401

Giải thích các hệ số — vẽ đồ thị dự báo

Việc tính toán và vẽ đồ thị dự đoán có thể gặp khó khăn, nhưng gói {modelbased} từ hệ sinh thái {easystats} (easystats.github.io/easystats) giúp việc này trở nên dễ dàng đối với nhiều loại mô hình

```
library(modelbased)
estimate_relation(fit_flipper_int) |>
  plot(show_data = TRUE)
```



Giải thích các hệ số — dự đoán có điều kiện và biên

Làm thế nào để tính toán/minh họa các dự đoán của mô hình cho một tập con các biến độc lập?

```
fit_flipper_3var <- lm(body_mass ~ flipper_len + sex + species, data = penguins_clean)
```

Ví dụ

Bạn muốn tính toán/minh họa mối quan hệ giữa `body_mass` và `flipper_len` từ mô hình đã ước lượng ở trên, thì phải xử lý `sex` và `species` như thế nào?

¹ Các mối tương quan cấu trúc là do thiết kế lấy mẫu không cân bằng gây ra

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Làm thế nào để tính toán/minh họa các dự đoán của mô hình cho một tập hợp con các biến độc lập?

```
fit_flipper_3var <- lm(body_mass ~ flipper_len + sex + species, data = penguins_clean)
```

Ví dụ

Bạn muốn tính toán/minh họa mối quan hệ giữa `body_mass` và `flipper_len` từ mô hình đã ước lượng ở trên, thì phải xử lý `sex` và `species` như thế nào?

- **Dự đoán có điều kiện:** phần mềm cố định từng biến độc lập không phải là biến trọng tâm ở một giá trị cụ thể (ví dụ: giá trị trung bình đối với các biến định lượng và hạng mục xuất hiện nhiều nhất đối với các biến định tính) → cách đơn giản nhất, nhưng việc lựa chọn tham chiếu có thể tùy ý và kết quả tính toán thậm chí có thể sai lệch nhẹ trong các mô hình liên quan đến biến đổi phi tuyến (do *bất đẳng thức Jensen*)

¹ Các mối tương quan cấu trúc là do thiết kế lấy mẫu không cân bằng gây ra

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Làm thế nào để tính toán/minh họa các dự đoán của mô hình cho một tập con các biến độc lập?

```
fit_flipper_3var <- lm(body_mass ~ flipper_len + sex + species, data = penguins_clean)
```

Ví dụ

bạn muốn tính toán/minh họa mối quan hệ giữa `body_mass` và `flipper_len` từ mô hình đã ước lượng ở trên, thì phải xử lý `sex` và `species` như thế nào?

- **Dự đoán có điều kiện:** phần mềm cố định từng biến độc lập không phải là biến trọng tâm ở một giá trị cụ thể (ví dụ: giá trị trung bình đối với các biến định lượng và hạng mục xuất hiện nhiều nhất đối với các biến định tính) → dễ nhất, nhưng việc lựa chọn tham chiếu có thể tùy ý và kết quả tính toán thậm chí có thể hơi sai trong các mô hình liên quan đến (các) phép biến đổi phi tuyến (do *bất đẳng thức Jensen*)
- **dự đoán biên:** phần mềm tính toán các dự đoán cho các giá trị/mức độ khác nhau của biến trọng tâm và biến dự báo không trọng tâm, sau đó tính trung bình các dự báo đó trên các biến dự báo không trọng tâm → **tổng hợp**, nhưng khó nắm bắt hơn vì có nhiều phương án khác nhau để tính toán *lưới tham chiếu* (tùy thuộc vào việc người ta muốn giữ lại hay loại bỏ các mối tương quan thực tế hay cấu trúc giữa các biến độc lập¹)

¹ Các mối tương quan cấu trúc là do thiết kế lấy mẫu không cân bằng gây ra

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Dự đoán có điều kiện về tác động của flipper_len đối với body_mass

```
cond_pred <- estimate_relation(fit_flipper_3var,  
                              by = "flipper_len")
```

cond_pred

Dự đoán dựa trên mô hình


flipper_len	Dự đoán	SE	Khoảng tin cậy 95%
-------------	---------	----	--------------------

172,00	3078,47	51,04	[2978,05, 3178,88]
178,56	3209,75	37,35	[3136,28, 3283,22]
185,11	3341,01	29,68	[3282,64, 3399,39]
191,67	3472,30	32,59	[3408,18, 3536,42]
198,22	3603,56	44,05	[3516,91, 3690,21]
204,78	3734,84	59,28	[3618,23, 3851,46]
211,33	3866,11	76,05	[3716,50, 4015,72]
217,89	3997,39	93,54	[3813,38, 4181,41]
224,44	4128,65	111,41	[3909,49, 4347,82]
231,00	4259,94	129,50	[4005,19, 4514,69]

Biến dự đoán: khối lượng cơ thể Các biến điều chỉnh: chiều dài vảy

Các biến giải thích được kiểm soát: sex (nữ), species (Adelie)

```
plot(cond_pred, show_data = TRUE)
```



Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Dự đoán có điều kiện về tác động của `flipper_len` đối với `body_mass`

```
cond_pred <- estimate_relation(fit_flipper_3var,  
                              by = "flipper_len")
```

`cond_pred`

Dự đoán dựa trên mô hình


flipper_len	Dự báo	SE	Khoảng
tin cậy 95%			
172,00	3.078,47	51,04	[2978,05; 3178,88]
178,56	3209,75	37,35	[3136,28, 3283,22]
185,11	3341,01	29,68	[3282,64, 3399,39]
191,67	3472,30	32,59	[3408,18, 3536,42]
198,22	3603,56	44,05	[3516,91, 3690,21]
204,78	3734,84	59,28	[3618,23, 3851,46]
211,33	3866,11	76,05	[3716,50, 4015,72]
217,89	3997,39	93,54	[3813,38, 4181,41]
224,44	4128,65	111,41	[3909,49, 4347,82]
231,00	4259,94	129,50	[4005,19, 4514,69]

Biến được dự đoán: `body_mass` Các biến điều chỉnh:

`flipper_len`

Các biến độc lập được kiểm soát: giới tính (nữ), loài (Adelie)

```
plot(cond_pred, show_data = TRUE)
```



Lưu ý: Ở đây, các dự đoán có điều kiện được đưa ra cho chim cánh cụt Adelie cái; trong mô hình cụ thể này (nhưng không phải nói chung), một tham chiếu khác (ví dụ: chim cánh cụt Gentoo đực) sẽ chỉ dịch chuyển đường hồi quy lên hoặc xuống, nhưng sẽ không thay đổi độ dốc vì không có tương tác nào được xem xét và các hiệu ứng là tuyến tính

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Dự đoán biên về ảnh hưởng của `flipper_len` đối với `body_mass` (phương pháp “trung bình”)

```
marg_avg_pred <- estimate_means( fit_flipper_3var,  
  by = list(flipper_len = penguins_clean$flipper_len), estimate =  
  "average")
```


```
as_tibble(marg_avg_pred)
```

Một bảng tibble: 54 x 7

	flipper_len	Trung bình	SE	CI_low	CI_high	t	df
	<int>	<dbl>	<dbl>	<dbl>		<dbl>	<int>
1	172	3078,51,0		2978.	3179,60,3		328
2	174	3119,46,5		3027.	3210,67,1		328
3	176	3159,42,2		3075.	3242,74,8		328
4	178	3309,40,2		3230.	3388,82,4		328
5	180	3636,42,4		3553.	3720,85,8		328

còn 49 hàng nữa

```
plot(marg_avg_pred, show_data = TRUE)
```



Lưu ý: ở đây, dự đoán biên là giá trị trung bình của các giá trị dự đoán cho tất cả các con chim cánh cụt được lấy mẫu có cùng chiều dài vây và có thể khác nhau về giới tính hoặc loài
→ giữ nguyên mối tương quan giữa các biến độc lập và giữ nguyên phân phối của các biến độc lập không phải là biến trọng tâm (tức là các cá thể được lấy mẫu có giới tính và loài khác nhau thường có trọng lượng lớn hơn)

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Dự đoán biên về ảnh hưởng của `flipper_len` đối với `body_mass` (nhường phần “trung bình”)

```
marg_avg_pred <- estimate_means( fit_flipper_3var,  
  by = list(flipper_len = penguins_clean$flipper_len), estimate =  
  "average")
```

```
as_tibble(marg_avg_pred)
```

Một tibble: 54 x 7

	flipper_len	Trung bình	SE	CI_low	CI_high	t	df
	<int>	<dbl>	<dbl>	<dbl>		<dbl>	<dbl>
1	172	3078,51,0	2978,			3179,60,3	328
2	174	3119,46,5	3027,			3210,67,1	328
3	176	3159,42,2	3075,			3242,74,8	328
4	178	3309,40,2	3230,			3388,82,4	328
5	180	3636,42,4	3553,			3720,85,8	328

i 49 hàng nữa

```
penguins_clean |>
```

```
  select(flipper_len, sex, species) -> grid_avg
```

```
grid_avg |>
```

```
  mutate(pred = predict( fit_flipper_3var,  
    newdata = grid_avg)) -> grid_avg
```

```
grid_avg |>
```

```
  summarise(Mean = mean(pred), .by = "flipper_len") |>  
  arrange(flipper_len)
```

Một bảng: 54 x 2

flipper_len	Trung bình
<int>	<dbl>

1	172 3078.
2	174 3119.
3	176 3159.
4	178 3309.
5	180 3636.

i 49 hàng nữa

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Dự đoán biên về ảnh hưởng của `flipper_len` đối với `body_mass` (phương pháp “tiêu chuẩn”)


```
marg_typic_pred <- estimate_means(  
  fit_flipper_3var,  
  by = "flipper_len", estimate =  
  "typical")
```

```
as_tibble(marg_typic_pred)
```

Một bảng tibble: 10 x 7

flipper_len	Giá trị trung bình	t	SE	CI_low	CI_high	df
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<int>
1	172	3593,84,3	3427.	3759.	42,6	328
2	179.	3724, 66,2	3594.	3855,	56,3	328
3	185.	3856. 48,4	3761.	3951,79,7		328
4	192.	3987. 31,6	3925.	4049, 126,		328
# thêm 5 hàng nữa	198.	4118. 18,8	4081.	4155.	219.	328

```
plot(marg_typic_pred, show_data = TRUE)
```



Lưu ý: ở đây, dự đoán biên là giá trị trung bình của các giá trị dự đoán, dựa trên giả định rằng bất kỳ chiều dài vây nào cũng có thể xuất hiện ở cả hai giới tính và ở bất kỳ loài nào với cùng xác suất → làm giảm mối tương quan giữa các biến độc lập và làm phẳng phân phối của các biến độc lập không phải là trọng tâm (tức là cả giới tính và tất cả các loài đều có cùng trọng số, như trong một thiết kế thí nghiệm cân bằng hoàn hảo)

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Dự đoán biên về ảnh hưởng của `flipper_len` đối với `body_mass` (phương pháp “tiêu chuẩn”)

```
marg_typic_pred <- estimate_means(
  fit_flipper_3var,
  by = "flipper_len", estimate =
  "typical")
```

```
as_tibble(marg_typic_pred)
```

```
# Một bảng tibble: 10 x 7
```

	flipper_len	Trung bình	SE	CI_low	CI_high	t	df
	<dbl>	<dbl>	<dbl>	<dbl>		<dbl>	<dbl>
1	172	3593,84,3	3427,		3759, 42,6		328
2	179.	3724.	66,2	3594.	3855,56,3		328
3	185.	3856.	48,4	3761.	3951, 79,7		328
4	192.	3987.	31,6	3925.	4049. 126.		328
5	198.	4118.	18,8	4081.	4155. 219.		328

```
# i 5 hàng nữa
```

```
expand_grid(
  flipper_len = seq(172, 231, length = 10), sex =
  unique(penguins_clean$sex),
  species = unique(penguins_clean$species)) -> grid_typic
```

```
grid_typic |> mutate(pred =
  predict(
    fit_flipper_3var,
    newdata = grid_typic)) -> grid_typic
```

```
grid_typic |>
  summarise(Mean = mean(pred), .by = "flipper_len") |>
  arrange(flipper_len)
```

```
# Một bảng: 10 x 2 flipper_len Giá
trị trung bình
```

	<dbl>	<dbl>
1	172	3593.
2	179,	3724
3	185.	3856.
4	192.	3987.
5	198.	4118.

```
# thêm 5 hàng nữa
```

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên


Dự đoán biên về tác động của `flipper_len` đối với `body_mass` (phương pháp “dân số”)

```
marg_pop_pred <- estimate_means( fit_flipper_3var,  
  by = "flipper_len", estimate =  
  "population")  
  
as_tibble(marg_pop_pred)
```

Một bảng tibble: 10 x 7

flipper_len	Giá trị trung bình	t	SE	CI_low	CI_high	df
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<int>
1	172	3627,84,0	3462.	3792,43,2	328	
2	179.	3758. 65,8	3629.	3888, 57,1	328	
3	185.	3890. 47,9	3795.	3984,81,1	328	
4	192.	4021. 31,0	3960.	4082, 130.	328	
# thêm 5 hàng nữa	198.	4152. 18,0	4117.	4187. 231.	328	

```
plot(marg_pop_pred, show_data = TRUE)
```



Lưu ý: ở đây, dự đoán biên là giá trị trung bình của các giá trị dự đoán, dựa trên giả định rằng bất kỳ chiều dài vây nào cũng có thể xuất hiện ở cả hai giới tính và ở bất kỳ loài nào với xác suất phản ánh dữ liệu mẫu → phá vỡ mối tương quan giữa các biến dự báo, nhưng vẫn giữ nguyên phân phối của các biến dự báo không phải là trọng tâm (tức là giới tính và loài được lấy mẫu càng nhiều thì trọng lượng càng lớn)

Giải thích các hệ số — dự đoán có điều kiện và dự đoán biên

Dự đoán biên về tác động của flipper_len đối với body_mass (nhưng nhân “dân số”)

```
marg_pop_pred <- estimate_means( fit_flipper_3var,  
  by = "flipper_len", estimate =  
  "population")
```

```
as_tibble(marg_pop_pred)
```

```
# Một bảng tibble: 10 x 7
```

	flipper_len	Trung bình	SE	CI_low	CI_high	t	df
	<dbl>	<dbl>	<dbl>	<dbl>		<dbl>	<dbl>
1	172	3627,84,0	3462,		3792,	43,2	328
2	179.	3758.	65,8	3629.		3888,	57,1
3	185.	3890.	47,9	3795.		3984,	81,1
4	192.	4021.	31,0	3960.		4082.	130.
5	198.	4152.	18,0	4117.		4187.	231.

```
# i 5 hàng nữa
```

```
expand_grid(  
  flipper_len = seq(172, 231, length = 10), sex =  
  penguins_clean$sex,  
  species = penguins_clean$species) -> grid_pop
```

```
grid_pop |>  
  mutate(pred = predict( fit_flipper_3var,  
    newdata = grid_pop)) -> grid_pop
```

```
grid_pop |>  
  summarise(Mean = mean(pred), .by = "flipper_len") |>  
  arrange(flipper_len)
```

```
# Một bảng: 10 x 2 flipper_len Giá  
trị trung bình
```

	<dbl>	<dbl>
1	172	3627.
2	179,	3758
3	185.	3890.
4	192.	4021.
5	198.	4152.

```
# i 5 hàng nữa
```

Mô hình tuyến tính tổng quát (GLM)

GLM — tại sao lại cần?

Các mô hình tuyến tính cổ điển (LM) rất hữu ích để mô hình hóa nhiều hiện tượng, bao gồm cả những hiện tượng mà mối quan hệ giữa biến độc lập và biến phụ thuộc không phải là tuyến tính (ví dụ: đa thức), nhưng chúng có chung hạn chế là được thiết kế để xấp xỉ một quá trình tạo dữ liệu vốn có bản chất là phân phối Gaussian (hãy nhớ rằng sai số được giả định là phân phối chuẩn)

Mô hình tuyến tính (LM) sẽ không hoạt động tốt với:

dữ liệu nhị phân (ví dụ: sự hiện diện/vắng mặt của một loài)

- tỷ lệ (ví dụ: tỷ lệ nở thành công trong một tổ), đặc biệt nếu các giá trị gần 0 hoặc 1 dữ liệu đếm (ví dụ: số loài được ghi lại bằng camera), đặc biệt nếu số lượng đếm thấp dữ liệu thời gian đến sự kiện (ví dụ: thời gian đến khi phân tán), đặc biệt nếu khoảng thời gian ngắn

Trong những trường hợp này, GLM là lựa chọn hàng đầu!

Lưu ý: hồi quy logistic và hồi quy Poisson là các ví dụ về GLM

GLM — các ký hiệu của mô hình GLM: ký hiệu đơn giản

$$\eta_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \dots + \beta_p x_{p,i}$$

với

- $E(Y) = \mu = g^{-1}(\eta)$
- $\text{Var}(Y) = \phi V(\mu)$

Chúng ta gọi:

- η dự báo tuyến tính
- g hàm liên kết (g^{-1} là hàm liên kết nghịch đảo)
- V là hàm phương sai
- ϕ là tham số phân tán

Lưu ý:

nó rất giống với mô hình LM nhưng có các yếu tố mới trong GLM, nếu $\phi = 1$ (trường hợp thông thường), phương sai của biến phụ thuộc là hàm trực tiếp của giá trị trung bình và do đó phụ thuộc vào η , vì vậy không cần đến σ trong trường hợp này!

GLM — quy trình tạo dữ liệu: mô phỏng dữ liệu


Hãy quay lại **chế độ Thần (Nữ thần)** → chúng ta giả vờ rằng mình biết thế giới của cô ấy tạo ra dữ liệu như thế nào

GLM — quy trình tạo dữ liệu: mô phỏng dữ liệu

Hãy quay lại **chế độ Thần (Nữ thần)** → chúng ta giả vờ rằng mình biết thế giới của cô ấy tạo ra dữ liệu như thế nào

Emerald Lion đã thông báo với chúng ta rằng trong thế giới của cô ấy, người ngoài hành tinh rời đi đến một hành tinh khác theo quy tắc này:

$$P(\text{sự chênh lệch}_i) = \frac{1}{1 + \exp^{-(2,197 + 1,5 \times \text{humans_eaten}_i)}}$$



Lưu ý: hàm $\frac{1}{1 + e^{-x}}$ được gọi là hàm logistic chuẩn và có sẵn trong R thông qua `plogis(x)`

GLM — quy trình tạo dữ liệu: mô phỏng dữ liệu

Hãy quay lại **chế độ Thần (Nữ thần)** → chúng ta giả vờ rằng mình biết thế giới của cô ấy tạo ra dữ liệu như thế nào

Emerald Lion đã thông báo với chúng ta rằng trong thế giới của cô ấy, người ngoài hành tinh rời đi đến một hành tinh khác theo quy tắc này:

$$P(i) = \frac{1}{1 + \exp^{-(2.197 + 1.5 \times \text{humans_eaten}_i)}}$$

Do đó, chúng ta có thể tạo dữ liệu về 35 người ngoài hành tinh theo công thức của E.L.:

```
set.seed(123)
Alien2 <- tibble(humans_eaten = rep(0:6, each = 5),
  prob_departure = plogis(-2.197 + 1.5*humans_eaten), departed = rbinom(n
    = 35, size = 1, prob = prob_departure))
```

GLM — quy trình tạo dữ liệu: kiểm tra dữ liệu

```
Alien2 |> slice(1:17) |> print(n = Inf)
```

Một bảng: 17 x 3

	số_người_bị_ăn <int>	prob_departure <dbl>	đã rời đi <int>
1	0	0,100	0
2	0	0,100	0
3	0	0,100	0
4	0	0,100	0
5	0	0,100	1
6	1	0,332	0
7	1	0,332	0
8	1	0,332	1
9	1	0,332	0
10	1	0,332	0
11	2	0,691	0
12	2	0,691	1
13	2	0,691	1
14	2	0,691	1
15	2	0,691	1
16	3	0,909	1
17	3	0,909	1

```
Alien2 |> slice(18:35) |> print(n = Inf)
```

Một bảng: 18 x 3

	số_người_bị_ăn <int>	prob_departure <dbl>	đã rời đi <int>
1	3	0,909	1
2	3	0,909	1
3	3	0,909	0
4	4	0,978	1
5	4	0,978	1
6	4	0,978	1
7	4	0,978	0
8	4	0,978	1
9	5	0,995	1
10	5	0,995	1
11	5	0,995	1
12	5	0,995	1
13	5	0,995	1
14	6	0,999	1
15	6	0,999	1
16	6	0,999	1
17	6	0,999	1
18	6	0,999	1

GLM — việc ước lượng mô hình: phương pháp thống kê tần số

Trong thực tế, các tham số mô hình là **chưa biết**, do đó chúng ta phải ước lượng chúng (chế độ "God mode" lại bị tắt)

```
fit_alien_glm <- glm(departed ~ humans_eaten, data = Alien2, family = binomial(link = "logit"))
```

Lưu ý:

- chúng ta đã sử dụng hàm `glm()` thay vì `lm()`
- chúng ta có một tham số mới là `binomial(link = "logit")` để chỉ ra rằng dữ liệu được sinh ra theo phân phối nhị thức và để chỉ định hàm liên kết mà mô hình phải sử dụng²

² hàm liên kết là hàm chuyển đổi dự đoán tuyến tính sang thang đo của biến phụ thuộc, hoặc trong trường hợp này sang xác suất (sẽ giải thích chi tiết hơn sau)

GLM — việc ước lượng mô hình: phương pháp thống kê tần số

Bảng tóm tắt cũng không khác biệt nhiều so với các bảng được tạo ra bằng hàm `lm()`

```
summary(fit_alien_glm)
```

```
Gọi:
glm(formula = departed ~ humans_eaten, family = binomial(link = "logit"), data = Alien2)
```

Hệ số:

	Ước lượng	Sai số chuẩn	Giá trị z	Xác suất
(Pr(> z)) (Hằng số)			-1,5952	0,8129 -
1,962 0,04973 *				
số_người_bị_ăn	1,0001	0,3411	2,932	0,00337 **

Mã ý nghĩa: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1

(Tham số phân tán cho họ nhị thức được lấy là 1)

Độ lệch không: 43,574 trên 34 bậc tự do Độ lệch dư: 27,667
trên 33 bậc tự do AIC: 31,667

Số lần lặp lại phương pháp Fisher Scoring: 5

GLM — vừa khít mô hình: phương pháp Bayes với {brms}

Việc ước lượng GLM bằng {brms} hơi khác một chút vì nó sử dụng một họ phân phối cụ thể cho dữ liệu nhị phân³

```
fit_alien_glm_brms <- brm(departed ~ humans_eaten, data = Alien2,  
                          family = bernoulli(link = "logit"),  
                          iter = 10000) # lần này cần nhiều hơn giá trị mặc định  
summary(fit_alien_glm_brms) # hoặc fixef(fit_alien_lm_brms) để tập trung vào các hệ số
```

Họ: bernoulli Liên kết: mu
= logit

Công thức: departed ~ humans_eaten

Dữ liệu: Alien2 (Số quan sát: 35)

Lần rút mẫu: 4 chuỗi, mỗi chuỗi có iter = 10000; warmup = 5000; thin = 1; tổng số lần
rút mẫu sau giai đoạn làm nóng = 20000

Hệ số hồi quy:

	Ước lượng	Sai số	Ước lượng	Giới hạn dưới 95% CI	Giới hạn trên 95% CI	Rhat
Bulk_ESS	Tail_ESS	Hàng số	-1,81	0,87	-3,67	-0,28 1,00 11.904
		11.479				
số người bị ăn thịt	1,09	0,35	0,50	1,89 1,00	7029	8505

Các kết quả hòa đã được lấy mẫu bằng phương pháp sampling(NUTS). Đối với mỗi tham số, Bulk_ESS và Tail_ESS là các thước đo kích thước mẫu hiệu quả, còn Rhat là hệ số giảm quy mô tiềm năng trên các chuỗi phân tách (khi hội tụ, Rhat = 1).

³ phân phối Bernoulli là một trường hợp đặc biệt của phân phối nhị thức khi chỉ có 1 lần thử

GLM — ước lượng mô hình: phương pháp Bayes với {nimble}

Việc định nghĩa GLM bằng tay với {nimble} tương đối đơn giản...

```
code_glm <- nimbleCode({ for (i
  in seq_len(N)) {
    # mô hình mô phỏng quá trình tạo dữ liệu logit(p[i]) <- intercept +
    slope*humans_eaten[i] departed[i] ~ dbin(p[i], 1)
  }
  # phân phối tiên nghiệm
  intercept ~ dnorm(mean = 0, sd = 2) slope ~
  dnorm(mean = 0, sd = 2)
})

constants_glm <- list(N = nrow(Alien2),
                      humans_eaten = Alien2$humans_eaten)

inits_glm <- list(intercept = 0, slope = 0)
```


GLM — ước lượng mô hình: phương pháp Bayes (kiểm tra dự đoán a priori)

... nhưng một lần nữa, chúng ta cần đảm bảo các phân phối tiên nghiệm là hợp lý (ở đây việc dự đoán trước sẽ còn khó khăn hơn)

```
set.seed(123) n_sims2 <-  
100  
  
prior_intercept2 <- rnorm(n = n_sims2, mean = 0, sd = 2) prior_slope2  
<- rnorm(n = n_sims2, mean = 0, sd = 2)  
  
expand_grid(sim = seq_len(n_sims2),  
            humans_eaten = seq(0, 6, by = 0.1)) |> mutate(prob =  
  plogis(prior_intercept2[sim] +  
    prior_slope2[sim] * humans_eaten)) -> prior_pred2  
  
ggplot(prior_pred2) + geom_histogram(aes(x =  
  prob))
```

```
ggplot(prior_pred2) +  
  geom_line(aes(y = prob, x = humans_eaten, group = sim))
```

- trông ổn



GLM — ước lượng mô hình: phương pháp Bayesian với {nimble}

Bây giờ chúng ta có thể ước lượng mô hình bằng {nimble}

```
fit_alien_glm_nimb <- nimbleMCMC(code = code_glm,  
                                constants = constants_glm,  
                                data = list(departed = Alien2$departed),  
                                inits = inits_glm, nchains = 4, setSeed = 1:4, nburnin =  
                                4000)  
fit_alien_glm_nimb_d <- as_draws(fit_alien_glm_nimb) summary(fit_alien_glm_nimb_d)
```

Một bảng: 2 x 10

```
fit_alien_glm_nimb_d <- as_draws(fit_alien_glm_nimb) tóm tắt(fit_alien_glm_nimb_d)
```

biến	trung bình	trung vị	độ lệch chuẩn	mad	q5	q95	rhat	ess_bulk	ess_tail
<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 hằng số	-1,46	-1,42	0,738	0,724	-2,73	-0,318	1,00	1326.	2476
2 hệ số góc	1,00	0,977	0,321	0,312	0,526	1,57	1,00	1256.	2159.

GLM — Kết quả ước lượng mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

glm()

```
# Một bảng tibble: 2 x 5
```

Tham số	Ước lượng	Độ lệch chuẩn	2,5 %	97,5 %
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 (Hằng số cắt)	-1,60	0,813	-3,43	-0,143
2 số người bị ăn thịt	1,00	0,341	0,440	1,82

brms::brm()

```
# Một bảng: 2 x 5
```

Tham số	Giá trị ước lượng	Sai số ước lượng	Q2,5
<chr>	<dbl>	<dbl>	<dbl>
1 Hằng số	-1,81	0,866	-3,67
2 số người bị ăn thịt	1,09	0,354	0,499

nimble::nimbleMCMC()

```
# Một bảng: 2 x 5
```

biến	trung bình	độ lệch chuẩn	2,5%	97,5%
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 hằng số	-1,46	0,738	-3,06	-0,118
2 độ dốc	1,00	0,321	0,440	1,71

GLM — Kết quả ước lượng mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

glm()

```
# Một bảng tibble: 2 x 5
  Tham số      Ước lượng `Độ lệch chuẩn` `2,5 %` `97,5 %`
  <chr>        <dbl>          <dbl>    <dbl>    <dbl>
1 (Hàng số cắt) -1,60          0,813 -3,43    -0,143
2 số người bị ăn thịt 1,00          0,341  0,440    1,82
```

brms::brm()

```
# Một bảng: 2 x 5
  Tham số      Ước lượng Sai số ước lượng Q2,5 Q97,5
  <chr>        <dbl>    <dbl> <dbl> <dbl>
1 Hàng số      -1,81    0,866 -3,67 -0,281
2 số người bị ăn thịt 1,09    0,354 0,499 1,89
```

nimble::nimbleMCMC()

```
# Một bảng: 2 x 5
biến      trung bình độ lệch chuẩn `2,5%` `97,5%`
  <chr>    <dbl> <dbl> <dbl>    <dbl>
1 hàng số -1,46 0,738 -3,06    -0,118
2 độ dốc  1,00 0,321 0,440    1,71
```

- các ước lượng phù hợp với nhau và tất cả các khoảng tin cậy đều bao gồm các giá trị thực

GLM — Kết quả ước lượng mô hình: So sánh các ước lượng

Hãy so sánh các kết quả

`glm()`

```
# Một bảng: 2 x 5
  Tham số      Ước lượng `Độ lệch chuẩn` `2,5 %` `97,5 %`
<chr>         <dbl>         <dbl>         <dbl>         <dbl>
1 (Hàng số cắt) -1,60      0,813 -3,43      -0,143
2 số người bị ăn thịt 1,00      0,341  0,440      1,82
```

`brms::brm()`

```
# Một bảng: 2 x 5
  Tham số      Giá trị ước lượng Sai số ước lượng      Q2,5
Q97,5
<chr>         <dbl>         <dbl> <dbl> <dbl>
1 Hàng số      -1,81      0,866 -3,67 -0,281
2 số người bị ăn thịt 1,09      0,354 0,499 1,89
```

`nimble::nimbleMCMC()`

```
# Một bảng: 2 x 5
biến      trung bình độ lệch chuẩn `2,5%` `97,5%`
<chr>     <dbl> <dbl> <dbl>         <dbl>
1 hàng số -1,46 0,738 -3,06      -0,118
2 độ dốc  1,00 0,321 0,440      1,71
```

- các ước lượng đều phù hợp và tất cả các khoảng tin cậy đều bao gồm các giá trị thực
- chúng tôi chưa bao giờ thu được giá trị -2,197 (hàng số) hay 1,5 (hệ số góc) bởi vì, một lần nữa, một mẫu hiếm khi phản ánh hoàn hảo các giá trị ở cấp độ dân số

GLM — việc ước lượng mô hình: phần phụ về các hàm liên kết

Cái gọi là *logit* (hay đơn vị logistic, hay log-odds) là gì?

```
fit_alien_glm <- glm(departed ~ humans_eaten, data = Alien2, family = binomial(link = "logit"))
```

- Đây là hàm nghịch đảo của hàm logistic chuẩn, và được định nghĩa như sau: $\text{logit}(p) = \log \frac{p}{1-p}$

chứng minh:

$$\frac{1}{1+e^{-\text{logit}(p)}} = \frac{1}{1+e^{-\log \frac{p}{1-p}}} = \frac{1}{1+\frac{1}{\frac{p}{1-p}}} = \frac{1}{1+\frac{1-p}{p}} = \frac{1}{\frac{p+1-p}{p}} = \frac{1}{\frac{1}{p}} = p$$

GLM — việc ước lượng mô hình: phần phụ về các hàm liên kết

Cái gọi là *logit* (hay đơn vị logistic, hay log-odds) là gì?

```
fit_alien_glm <- glm(departed ~ humans_eaten, data = Alien2, family = binomial(link = "logit"))
```

- Đây là hàm nghịch đảo của hàm logistic chuẩn, và được định nghĩa như sau: $\text{logit}(p) = \log \frac{p}{1-p}$

Chứng minh:


$$\frac{1}{1+e^{-\text{logit}(p)}} = \frac{1}{1+e^{-\log \frac{p}{1-p}}} = \frac{1}{1+\frac{1}{e^{\log \frac{p}{1-p}}}} = \frac{1}{1+\frac{1}{\frac{p}{1-p}}} = \frac{1}{1+\frac{1-p}{p}} = \frac{1}{\frac{p+1-p}{p}} = \frac{1}{\frac{1}{p}} = p$$

đây là thang đo mà trên đó hàm dự đoán tuyến tính của mô hình GLM hiện tại được biểu diễn, vì logit được phép dao động trong khoảng $-\infty$ và ∞ và p trong khi bị giới hạn trong khoảng từ 0 đến 1

Còn có các hàm liên kết khác có thể áp dụng cho họ hàm nhị thức (ví dụ: Cauchy, Probit); chúng cũng có dạng chữ S, nhưng không hoàn toàn giống nhau


GLM — Phù hợp mô hình: Phần phụ về các hàm liên kết

Một số hàm liên kết được sử dụng cho họ phân phối nhị thức



GLM — ước lượng mô hình: phần giới thiệu về các hàm liên kết

Một số hàm liên kết được sử dụng cho họ phân phối nhị thức



Lưu ý:

- logit là một *hàm liên kết chuẩn*, có các tính chất toán học tốt nhất trong số các lựa chọn thay thế, đó là lý do tại sao nó là giá trị mặc định của hàm `binomial()`
 - trong thống kê Bayes, việc tuân thủ các hàm liên kết chuẩn mang lại ít lợi ích hơn so với thống kê tần số, nhưng việc lấy mẫu MCMC có thể khó khăn đối với một số hàm liên kết không chuẩn và cách diễn giải các tham số có thể còn phức tạp hơn những gì chúng ta sắp thấy trong vài trang trình chiếu tiếp theo
- nếu bạn mới bắt đầu, hãy sử dụng logit cho mô hình nhị thức (và log cho mô hình GLM Poisson)

GLM — Mô hình GLM Poisson, dữ liệu

Một mô hình GLM rất hữu ích khác là mô hình GLM Poisson, được sử dụng để ước lượng dữ liệu đếm

Lần này, chúng ta sẽ sử dụng trực tiếp dữ liệu thực tế, đó là dữ liệu về các loài chim ở Thụy Sĩ mà bạn hẳn đã tải xuống rồi:

```
territories <- read_csv("data_MHB/data-territories.csv") species_count <-  
read_csv("data_MHB/header-species-count.csv")  
  
territories |>  
  summarise(territories_sum = sum(territories_total, na.rm = TRUE),  
            .by = c(nameeg, namelt)) |>  
  slice_max(territories_sum, n = 6) |> pull(namelt) ->  
  top6sp  
  
territories |>  
  filter(namelt %in% top6sp & year == 2000) |> summarise(territories_top6 =  
    sum(territories_total, na.rm = TRUE),  
            .by = c(nameeg, samplearea_id)) |>  
  left_join(số_loài |> filter(năm == 2000)) -> các_khu_vực_hàng_đầu_năm_2000
```

GLM — Mô hình GLM Poisson, dữ liệu

Một mô hình GLM rất hữu ích khác là mô hình GLM Poisson, được sử dụng để ước lượng dữ liệu đếm

Lần này, chúng ta sẽ sử dụng trực tiếp dữ liệu thực tế, đó là dữ liệu về các loài chim ở Thụy Sĩ mà bạn hẳn đã tải xuống rồi:

```
territories_top6_2000
```

```
# Một bảng: 1.584 × 12
```

nameeg	samplearea_id	territories_top6	`x-koord`	`y-koord`	lon	lat	năm	route_length
<chr>	<dbl>		<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 Than ~	268	8	2.725.500	1.182.500	9,08	46,8	2000	4444
2 Than ~	269	1	2.497.500	1.118.500	6,11	46,2	2000	6232
3 Than ~	270	34	2.725.500	1.214.500	9,09	47,1	2000	4081
4 Than ~	271	0	2.503.500	1.134.500	6,18	46,4	2.000	4483
5 Than ~	272	34	2.725.500	1.230.500	9,10	47,2	2.000	4939

```
# i 1.579 hàng nữa
```

```
# i 3 biến khác: độ cao trung vị <dbl>, số lần thăm dò <dbl>, số loài được ghi nhận <dbl>
```

GLM — Mô hình GLM Poisson, ước lượng

Hãy xây dựng mô hình cho số lượng khu vực được ghi nhận là đã bị chiếm đóng tại một khu vực mẫu (năm 2000), theo độ cao trung vị và số lần thăm dò đã thực hiện:

```
fit_bird_glm <- glm(territories_top6 ~ độ cao trung vị + n_visits, data = territories_top6_2000, family = poisson(link = "log"))
summary(fit_bird_glm)
```

Gọi:

```
glm(formula = territories_top6 ~ median_elevation + n_visits, family = poisson(link = "log"), data = territories_top6_2000)
```

Hệ số:

	Ước lượng	Sai số chuẩn	Giá trị z	Xác suất (Pr(> z))
(Hằng số)	-3,93424937	0,19283817	-20,40	<2e-16 ***
độ cao trung vị	-0,00043192	0,00001432	-30,16	<2e-16 ***
số_lần_thăm	2,40357555	0,06316170	38,05	<2e-16 ***

Mã ý nghĩa: 0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1

(Tham số phân tán cho họ Poisson được lấy là 1)

Độ lệch không: 28575 trên 1583 bậc tự do Độ lệch dư: 20463 trên 1581 bậc tự do AIC: 25772


GLM — dự đoán và giải thích

Ở cấp độ của hàm dự đoán tuyến tính (ở đây là logit và sau đó là log), việc giải thích hoàn toàn giống như trong

```
lm  
coef(fit_alien_glm)
```

```
(Hằng số) humans_eaten  
-1,595208      1,000088
```

```
estimate_link(fit_alien_glm) |>  
plot(numeric_as_discrete = FALSE)
```



Giải thích

- trung bình, *logit của việc rời đi* là -1,6 khi không có người nào bị ăn thịt
- trung bình, mỗi người bị ăn thịt thêm sẽ làm tăng *logit của việc rời đi* thêm 1

GLM — dự đoán và giải thích

Ở cấp độ của hàm dự đoán tuyến tính (ở đây là logit và sau đó là log), việc giải thích hoàn toàn giống như trong

IM
hệ số (mô hình GLM chìm)

(Hằng số) độ cao trung vị


-3,9342493729

-0,0004319178

số_lần_ghé_thăm

2,4035755506

```
estimate_link(fit_bird_glm) |> plot()
```



Giải thích

- Trung bình, *log số lượng lãnh thổ* là -3,93 khi độ cao trung vị là 0m và số lượt truy cập là 0 trung bình, mỗi mét tăng thêm trong độ cao trung bình làm
- thay đổi *log số lượng vùng lãnh thổ* là -0,000432 trung bình, mỗi lượt thăm thêm làm tăng *log*
- số lượng lãnh thổ* thêm 2,4


GLM — dự đoán và giải thích

Ở cấp độ biến phản ứng, dự đoán và giải thích có sự khác biệt

```
hệ số(fit_alien_glm)
```

(Hằng số)	humans_eaten
-1,595208	1,000088

```
estimate_relation(fit_alien_glm,  
  by = list(humans_eaten = seq(0, 6, length = 100))) |>  
  plot(show_data = TRUE, numeric_as_discrete = FALSE)
```



Giải thích

- trung bình, mỗi người bị ăn thêm sẽ làm tăng *xác suất rời đi* độ dốc

$$e = 2,72 \text{ lần}$$

GLM — dự đoán và giải thích

Ở cấp độ biến phản ứng, dự đoán và giải thích có sự khác biệt

hệ số (mô hình GLM chim)

(Hằng số) độ cao trung vị

-3,9342493729


số_lần_ghé_thăm

-0,0004319178

2,4035755506

```
estimate_relation(fit_bird_glm) |>
```

```
vẽ(show_data = FALSE) # không hiển thị điểm dữ liệu để dễ nhìn
```



Giải thích

- Trung bình, mỗi mét tăng thêm về độ cao trung bình sẽ làm tăng số lượng khu vực lên $\text{độ dốc} \times 100 = -0,0432\%$ trung bình, cứ thêm 1.000 mét độ cao trung vị thì số lượng khu vực tăng thêm $\text{độ dốc} \times 1000 = -35,1\%$

$$100 \times (e^{-0,0432} - 1) =$$

Các bài kiểm tra

Kiểm thử — các chiến lược kiểm thử chính

Bối cảnh	Cách tiếp cận theo trường phái tần số	Phương pháp Bayes
so sánh không lồng nhau (không phải là kiểm định <i>đúng nghĩa</i>)		AIC / BIC So sánh BF / LOO-CV hoặc WAIC
so sánh hai mô hình lồng nhau (chung)	Kiểm định F (cho LM) / Kiểm định LRT (cho GLM [*])	So sánh BF / LOO-CV hoặc WAIC / PIP
Trường hợp đặc biệt: mô hình so với mô hình không GLM [*]) của	Kiểm định F (cho LM) / Kiểm định LRT (cho	So sánh BF / LOO-CV hoặc WAIC / PIP
	toàn bộ so với chỉ có hằng số	So sánh BF / LOO-CV hoặc WAIC / PIP
trường hợp đặc biệt: hiệu ứng tổng thể của một biến GLM [*]) giữa	Kiểm định F (cho LM) / Kiểm định LRT (cho	BF (Savage-Dickey) / khoảng tin cậy / PIP
hệ số so với một giá trị cố định (thường là 0)	mô hình đầy đủ so với mô hình loại bỏ biến Kiểm định t/z của Wald ^{**} (cho LM/GLM [*]) trên hệ số	

^{*} GLM với họ gần đúng (tức là $\phi \neq 1$), nên được xử lý như một bài kiểm tra LM

^{**} Kiểm định Wald cho kết quả kém khi mẫu nhỏ hoặc các tham số gần giới hạn, và có các phương pháp thay thế (ví dụ: bootstrap tham số)

Kiểm thử — các chiến lược kiểm thử chính

Bối cảnh	Cách tiếp cận tần số	Cách tiếp cận Bayes
so sánh không lồng nhau (không phải là kiểm định <i>đúng nghĩa</i>)		AIC / BIC So sánh BF / LOO-CV hoặc WAIC
so sánh hai mô hình lồng nhau (chung)	Kiểm định F (cho LM) / Kiểm định LRT (cho GLM [*])	So sánh BF / LOO-CV hoặc WAIC / PIP
trường hợp đặc biệt: mô hình so với mô hình không GLM [*]) của	Kiểm định F (cho LM) / Kiểm định LRT (cho	So sánh BF / LOO-CV hoặc WAIC / PIP
	toàn bộ so với chỉ có hằng số	So sánh BF / LOO-CV hoặc WAIC / PIP
trường hợp đặc biệt: tác động tổng thể của một biến định LRT (đối với mô hình tuyến tính tổng quát (GLM [*]) của	Kiểm định F (đối với mô hình tuyến tính) / Kiểm	BF (Savage-Dickey) / khoảng tin cậy / PIP
	so sánh hệ số biến bị loại bỏ	
hệ số so với một giá trị cố định (thường là 0)	Kiểm định t/z của Wald ^{**} (cho LM/GLM [*]) trên	
	hệ số	

* GLM với họ gần đúng (tức là $\phi \neq 1$), nên được xử lý như một bài kiểm tra LM

** Kiểm định Wald cho kết quả kém khi mẫu nhỏ hoặc các tham số gần giới hạn, và có các phương pháp thay thế (ví dụ: bootstrap tham số)

Thuật ngữ kỹ thuật:

- AIC = Tiêu chí thông tin Akaike
- BIC = Tiêu chí thông tin Bayes
- BF = Hệ số Bayes
- LOO-CV = xác nhận chéo loại trừ một mẫu
- LRT = kiểm định tỷ số khả năng
- PIP = xác suất bao gồm a posteriori

Kiểm thử — các chiến lược kiểm thử

chính WAIC = Tiêu chí thông tin áp dụng rộng rãi = Tiêu chí thông tin Watanabe–Akaike

- LRT = kiểm định tỷ số khả năng
- PIP = xác suất bao gồm a posteriori

Kiểm thử — các chiến lược kiểm thử chính

Bối cảnh	Phương pháp thống kê tần số	Phương pháp Bayes
so sánh không lồng nhau (không phải là một bài kiểm tra <i>đúng nghĩa</i>)		AIC / BIC So sánh BF / LOO-CV hoặc WAIC
so sánh hai mô hình lồng nhau (chung)	Kiểm định F (cho LM) / Kiểm định LRT (cho GLM [*])	So sánh BF / LOO-CV hoặc WAIC / PIP
trường hợp đặc biệt: mô hình so với mô hình không GLM [*]) của	Kiểm định F (cho LM) / Kiểm định LRT (cho	So sánh BF / LOO-CV hoặc WAIC / PIP
	toàn bộ so với chỉ có hằng số	So sánh BF / LOO-CV hoặc WAIC / PIP
trường hợp đặc biệt: tác động tổng thể của một biến với GLM [*]) của	Kiểm định F (đối với LM) / Kiểm định LRT (đối	BF (Savage-Dickey) / khoảng tin cậy / PIP
	so sánh hệ số biến bị loại bỏ	
hệ số so với một giá trị cố định (thường là 0)	Kiểm định t/z của Wald ^{**} (cho LM/GLM [*]) trên	
	hệ số	

^{*} GLM với họ gần đúng (tức là $\phi \neq 1$), nên được xử lý như một bài kiểm tra LM

^{**} Kiểm định Wald cho kết quả kém khi mẫu nhỏ hoặc các tham số gần giới hạn, và có các phương pháp thay thế (ví dụ: bootstrap tham số)

- WAIC = Tiêu chí thông tin áp dụng rộng rãi = Tiêu chí thông tin Watanabe-Akaike

Thuật ngữ kỹ thuật:

- AIC = Tiêu chí thông tin Akaike
- BIC = Tiêu chí thông tin Bayes
- BF = Hệ số Bayes
- LOO-CV = xác nhận chéo loại trừ một mẫu
- LRT = kiểm định tỷ số khả năng
- PIP = xác suất bao gồm a posteriori

Kiểm thử — các chiến lược kiểm thử chính

Lưu ý:

- dù bạn làm gì đi nữa, dữ liệu biến phụ thuộc phải hoàn toàn giống nhau (cẩn thận với các giá trị bị loại bỏ tự động do các giá trị NA trong các biến độc lập)
- để giảm các kết quả dương tính giả, hãy thực hiện các kiểm định theo thứ tự sau
 - : mô hình đầy đủ so với mô hình không (null) → mô hình đầy đủ so với mô hình loại bỏ biến → hệ số so với giá trị cố định

- LRT = kiểm định tỷ số khả năng
- PIP = xác suất bao gồm a posteriori

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình không)?

Kiểm định F để kiểm tra " H ": phương sai được giải thích bởi 2 mô hình LM

```
fit_alien_lm      <- lm(size ~ humans_eaten, data = Alien)
fit_alien_lm_null <- lm(size ~ 1, data = Alien)
anova(fit_alien_lm, fit_alien_lm_null)
```

Bảng phân tích phương sai

Mô hình 1: size ~ humans_eaten Mô hình

2: size ~ 1

	Res.Df	RSS	Df	Tổng bình phương	F	Xác suất (Pr(>F))
1	10	31,031				
2	11	76,153	-1	-45,122	14,541	0,003411 **

Mã ý nghĩa: 0 '****' 0,001 '***' 0,01 '**' 0,05 '.' 0,1 ' ' 1

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình không)?

Kiểm định F để kiểm tra giả thuyết " H ": phương sai được giải thích bởi hai

```
fit_alien_lm      <- lm(size ~ humans_eaten, data = Alien)
fit_alien_lm_null <- lm(size ~ 1, data = Alien)
anova(fit_alien_lm, fit_alien_lm_null)
```

Bảng phân tích phương sai

Mô hình 1: size ~ humans_eaten Mô hình

2: size ~ 1

	Res.Df	RSS	Df	Tổng bình phương	F	Pr(>F)
1	10	31,031				
2	11	76,153	-1	-45,122	14,541	0,003411 **

Mã ý nghĩa: 0 '****' 0,001 '***' 0,01 '**' 0,05 '.' 0,1 ' ' 1

Giải thích: chúng tôi bác bỏ mô hình không có ý nghĩa thống kê một cách có ý nghĩa và ủng hộ mô hình đầu tiên

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình

không)? Hệ số Bayes so sánh 2 mô hình tuyến tính (LM) bằng {brms} (đơn

```
fit_alien_lm_brms          <- brm(size ~ humans_eaten, data = Alien)
fit_alien_lm_brms_null <- brm(size ~ 1, data = Alien)
BF_lm <- bayes_factor(fit_alien_lm_brms, fit_alien_lm_brms_null) BF_lm$bf
```

[1] 222,6148

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình

không)? Hệ số Bayes so sánh 2 mô hình tuyến tính (LM) bằng {brms} (đơn

```
fit_alien_lm_brms          <- brm(size ~ humans_eaten, data = Alien)
fit_alien_lm_brms_null <- brm(size ~ 1, data = Alien)
BF_lm <- bayes_factor(fit_alien_lm_brms, fit_alien_lm_brms_null) BF_lm$bf
```

[1] 222.6148

Giải thích: dữ liệu quan sát có khả năng xảy ra cao hơn 222,6 lần theo mô hình LM đầu tiên của chúng ta so với mô hình null

NHƯNG thật không may là có một vấn đề, không giống như các phân phối hậu nghiệm vốn không nên quá nhạy cảm với các phân phối tiên nghiệm, hệ số Bayes lại rất nhạy cảm, và các phân phối tiên nghiệm mặc định trong {brms} là mơ hồ và không phù hợp, khiến chúng không thích hợp cho nhiệm vụ này

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình

không)? Hệ số Bayes so sánh 2 mô hình tuyến tính (LM) bằng {brms} (giả

```
priors_brms2 <- c(prior(normal(0, 5), class = "b"),  
                 prior(normal(50, 5), class = "Intercept"), prior(uniform(0, 5),  
                 class = "sigma", ub = 5))  
  
fit_alien_lm_brms2 <- brm(size ~ humans_eaten, data = Alien, prior = priors_brms2)  
fit_alien_lm_brms_null2 <- brm(size ~ 1, data = Alien, prior = priors_brms2[2:3, ]) BF_lm2 <-  
bayes_factor(fit_alien_lm_brms2, fit_alien_lm_brms_null2)  
BF_lm2$bf
```

```
[1] 10.94815
```

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau


Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình

không)? Hệ số Bayes so sánh 2 mô hình tuyến tính (LM) bằng {brms} (giả

```
priors_brms2 <- c(prior(normal(0, 5), class = "b"),  
                 prior(normal(50, 5), class = "Intercept"), prior(uniform(0, 5),  
                 class = "sigma", ub = 5))  
  
fit_alien_lm_brms2 <- brm(size ~ humans_eaten, data = Alien, prior = priors_brms2)  
fit_alien_lm_brms_null2 <- brm(size ~ 1, data = Alien, prior = priors_brms2[2:3, ]) BF_lm2 <-  
bayes_factor(fit_alien_lm_brms2, fit_alien_lm_brms_null2)  
BF_lm2$bf
```

```
[1] 10.94815
```

Giải thích: dữ liệu quan sát có khả năng xảy ra cao hơn 10,9 lần khi áp dụng mô hình LM đầu tiên của chúng tôi so với mô hình không, điều này thể hiện sự ủng hộ mạnh mẽ đối với mô hình của chúng tôi



Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình

không)? Xác suất bao gồm a posteriori khi so sánh 2 mô hình tuyến tính

```
code_pip <- nimbleCode({
  incl ~ dbin(p_incl, 1) # chúng tôi thêm một switch
  for (i in seq_len(N)) {
    size[i] ~ dnorm(
      mean = intercept + incl*slope*humans_eaten[i], sd = sigma)
  }
  # phân phối tiên nghiệm
  intercept ~ dnorm(mean = 50, sd = 5) slope ~
  dnorm(mean = 0, sd = 5) sigma ~ dunif(min =
  0, max = 5)
})

constants_pip <- list(p_incl = 0.5, N = nrow(Alien), humans_eaten = Alien$humans_eaten)
inits_pip <- list(intercept =
mean(Alien$size), slope = 0, sigma = 1)
```

Lưu ý:

- `p_incl` được cố định ở mức 0.5, phản ánh một giả định ban đầu trung lập
- nếu có nhiều biến độc lập, `incl` sẽ phải được nhân với tất cả các hệ số hồi quy tương ứng

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình

không)? Xác suất bao gồm a posteriori khi so sánh 2 mô hình tuyến tính

```
fit_alien_lm_nimb_pip <- nimbleMCMC(code = code_pip,
                                   constants = constants_pip,
                                   data = list(size = Alien$size), inits =
                                   inits_pip,
                                   nchains = 4, setSeed = 1:4,
                                   nburnin = 4000, progressBar =
                                   FALSE)

proba_incl <- mean(sapply(fit_alien_lm_nimb_pip, \(chain) mean(chain[, "incl"]))) # trung bình trên các chuỗi proba_incl

[1] 0.950375
```

Kiểm định — ví dụ về so sánh hai mô hình lồng nhau

Mô hình của chúng ta có tốt hơn mô hình chỉ có hằng số (tức là mô hình

không)? Xác suất bao gồm a posteriori khi so sánh 2 mô hình tuyến tính

```
fit_alien_lm_nimb_pip <- nimbleMCMC(code = code_pip,
                                   constants = constants_pip,
                                   data = list(size = Alien$size), inits =
                                   inits_pip,
                                   nchains = 4, setSeed = 1:4,
                                   nburnin = 4000, progressBar =
                                   FALSE)

proba_incl <- mean(sapply(fit_alien_lm_nimb_pip, \(chain) mean(chain[, "incl"]))) # trung bình trên các chuỗi proba_incl
```

[1] 0.950375

Giải thích

1. có 95% xác suất hậu nghiệm rằng tác động của số lượng người bị ăn đối với kích thước của người ngoài hành tinh là có thật, so với 5% xác suất hậu nghiệm rằng dữ liệu cũng phù hợp với mô hình không có tác động
2. vì `p_incl` được cố định ở 0,5, `proba_incl` trực tiếp xác định BF, dẫn đến $\frac{\text{proba_incl}}{(1 - \text{proba_incl})} = 19,2$ (lưu ý, điều này có chút khác biệt so với BF của {brms} vì phương pháp sau này tự động căn giữa các biến giải thích được nhân với các giá trị rút mẫu từ phân phối tiên nghiệm)

Kiểm định — ví dụ về kiểm định các tham số

Các ước lượng tham số có khả năng bằng 0 không?

Kiểm định t để kiểm tra giả thuyết " H_0 " rằng các ước lượng tham số bằng 0

```
summary(fit_alien_lm)$coefficients # hoặc chỉ cần summary(fit_alien_lm)
```

	Ước lượng	Sai số chuẩn	Giá trị t	Pr(> t)
(Hằng số)	48,835310	1,3454140	36,297608	5,987821e-12
humans_eaten	2.374922	0.6228057	3.813263	3.410945e-03

Giải thích: cả hai tham số đều khác biệt đáng kể so với 0

Lưu ý:

- thông tin này được cung cấp trực tiếp từ các bảng tóm tắt đã xem trước đó

Kiểm định — ví dụ về kiểm định các tham số

Các ước lượng tham số có khả năng bằng 0 không?

sử dụng khoảng tin cậy để kiểm định giả thuyết H_0 rằng các ước lượng tham số bằng 0

```
fixef(fit_alien_lm_brms) # hoặc chỉ cần summary(fit_alien_lm_brms)
```

	Ước lượng	Sai số	ước lượng	Q2.5	Q97.5
Hằng số	48,82913	1,5129858	45,8069388	51,849559	
humans_eaten	2.37829	0.6995441	0.9932649	3.758505	

Giải thích: Giá trị 0 không nằm trong số các giá trị được coi là hợp lý ở mức độ tin cậy 95%

Lưu ý:

- thông tin này một lần nữa được cung cấp bởi các bảng tóm tắt đã xem trước đó

Các bài kiểm tra — kết luận

- việc kiểm định các tham số trực tiếp dễ dàng hơn nhiều nhưng lại làm tăng nguy cơ kết quả dương tính giả khi áp dụng kiểm định ý nghĩa giả thuyết không (NHST) (đây là lý do tại sao trước đó tôi đã khuyến nghị thứ tự kiểm định từ tổng quát đến cụ thể)
- trong thống kê Bayes, thứ tự này không cần thiết để kiểm soát tỷ lệ sai sót một cách chính thức (khác với NHST), nhưng thứ tự này vẫn là một thực hành khoa học tốt: các kết luận về một hệ số chỉ có ý nghĩa nếu mô hình/biến rộng hơn đó tự nó được dữ liệu ủng hộ
- trong thống kê Bayes, hệ số Bayes rất hấp dẫn vì nó có khả năng được áp dụng cho tất cả các tình huống kiểm định, tuy nhiên nó phụ thuộc rất nhiều vào các phân phối tiên nghiệm và do đó vào việc chia tỷ lệ nội bộ các biến số bởi phần mềm, điều này khiến nó trở thành một thước đo khó so sánh giữa các nghiên cứu, gây nghi ngờ về “thang đo” thông thường về mức độ mạnh của bằng chứng liên quan đến nó
- trong thống kê Bayes, dưới bất kỳ phân phối a priori liên tục nào, độ dốc thực sự liên tục cũng không bao giờ chính xác bằng không → H không có vị thế đặc biệt mà chỉ được xem như một giả thuyết trong số nhiều

Xây dựng mô hình

Xây dựng mô hình — các nguyên tắc cốt lõi

- cần thời gian để hình dung/nghiên cứu quá trình tạo ra dữ liệu
- Hãy xây dựng mô hình của bạn dựa trên kiến thức của bản thân, chứ
- không phải bằng cách thử và sai; các đường thẳng không phải là lựa chọn

duy nhất của bạn

(ví dụ: đa thức, phân đoạn, mô hình cộng gộp tổng quát)

- hãy nhớ rằng tham vọng của bạn cần được điều chỉnh phù hợp với lượng dữ liệu bạn có. Nguyên tắc

→ chung: bạn không nên ước lượng quá khoảng $N/10$ tham số

(nếu bạn muốn ước lượng nhiều tham số hơn mức đó, hãy thu thập thêm dữ liệu)

Xây dựng mô hình — Đơn giản hóa mô hình

Việc thêm một tham số bổ sung vào mô hình có cả ưu và nhược điểm: Ưu điểm:

- nó tăng cường sức mạnh (nếu nó giải thích được điều gì đó) nó giúp hiểu rõ hơn

⁴ mô tả các quy luật chỉ đúng trong mẫu hiện có mà không đúng trong tổng thể

Xây dựng mô hình — đơn giản hóa mô hình

Việc thêm một tham số bổ sung vào mô hình có những ưu và nhược điểm: Ưu điểm:

- nó làm tăng sức mạnh (nếu nó giải thích được điều gì đó) thì nó cũng làm tăng sự hiểu biết

Nhược điểm:

- nó làm giảm độ mạnh (nếu nó không giải thích được gì)
Nó có thể dẫn đến *hiện tượng quá khớp*
- nó làm giảm độ tin cậy của việc ước lượng các tham số khác (ví dụ: do *đa cộng tuyến*)

⁴ mô tả các quy luật chỉ đúng trong mẫu hiện có mà không đúng trong tổng thể

Xây dựng mô hình — đơn giản hóa mô hình

Việc thêm một tham số bổ sung vào mô hình có cả ưu và nhược điểm: Ưu điểm:

- nó làm tăng sức mạnh thống kê (nếu nó giải thích được điều gì đó) nó giúp tăng cường sự hiểu biết

Nhược điểm:

- nó làm giảm độ mạnh (nếu nó không giải thích được gì)
Nó có thể dẫn đến *hiện tượng quá khớp*
- nó làm giảm độ tin cậy của việc ước lượng các tham số khác (ví dụ: do *đa cộng tuyến*) quan sát đơn giản

→ này gợi ý một thực hành rất gây tranh cãi trong Sinh thái học: *đơn giản hóa mô hình*, tức là hoạt động bắt đầu từ một mô hình đầy đủ (mô hình có tất cả các biến đồng biến quan tâm), sau đó tiến hành giảm số lượng biến (và do đó là số lượng tham số) bằng cách loại bỏ những biến “không quan trọng”

⁴ mô tả các quy luật chỉ đúng trong mẫu hiện có mà không đúng trong tổng thể

Xây dựng mô hình — đơn giản hóa mô hình

Việc đơn giản hóa mô hình có được không?

Xây dựng mô hình — đơn giản hóa mô hình

Việc đơn giản hóa mô hình có được không?

Không!

nó làm tăng tỷ lệ kết quả dương tính giả lên rất nhiều nó làm

- tăng nguy cơ quá khớp với dữ liệu
- các bài kiểm tra, khoảng tin cậy và khoảng tin cậy không thể nắm bắt và truyền tải được sự không chắc chắn của chính quy trình lựa chọn mô hình
- chỉ riêng nhiều đã có thể ảnh hưởng đến việc biến nào được giữ lại và biến nào bị loại bỏ

→ Đừng làm thế!

Xây dựng mô hình — đơn giản hóa mô hình

Việc đơn giản hóa mô hình có được không?

Không!

Thay vào đó,

- lời khuyên đơn giản: hãy tuân thủ một *mô hình đầy đủ* duy nhất mà không quá phức tạp
- phạm vi chấp nhận được: loại bỏ các tương tác rất yếu (những nhược điểm về mặt thống kê được bù đắp bởi lợi ích lớn về sự đơn giản trong việc giải thích)
- các phương án thay thế: thực hiện *trung bình mô hình* (một sự kết hợp có trọng số của các ước lượng từ các mô hình thay thế) hoặc dựa vào các kỹ thuật *phạt*⁵

⁵ một mô hình duy nhất với nhiều tham số được sử dụng nhưng *phương pháp co hẹp* được áp dụng trên các ước lượng (theo trường phái tần số) hoặc trên các phân phối tiên nghiệm (theo trường phái Bayes) để ngăn chặn hiện tượng quá khớp

Giả định

Tính tuyến tính

- nếu không, việc biến đổi các biến phụ thuộc hoặc độc lập, đưa thêm các biến độc lập khác, các tương tác, hoặc sử dụng các mô hình phi tuyến (ví dụ: mô hình cộng gộp) có thể giúp ích

Tính tuyến tính

- nếu không, việc biến đổi biến phụ thuộc hoặc biến độc lập, đưa thêm các biến độc lập khác, xem xét các tương tác, hoặc sử dụng các mô hình phi tuyến (ví dụ: mô hình cộng gộp) có thể giúp ích

Các biến dự báo không có sai số

- nếu không, việc thêm các biến tiềm ẩn là đơn giản với phương pháp Bayes

Tính tuyến tính

- nếu không, việc biến đổi biến phụ thuộc hoặc biến độc lập, đưa vào các biến độc lập khác, tương tác, hoặc sử dụng các mô hình phi tuyến (ví dụ: mô hình cộng gộp) có thể giúp giải quyết vấn đề

Các biến dự báo không có sai số

- nếu không, việc thêm các biến tiềm ẩn là đơn giản khi áp dụng phương pháp Bayes


Các sai số được phân phối độc lập, đồng nhất và theo phân phối chuẩn

- Có nhiều lý do có thể dẫn đến sự sai lệch so với các giả định này, và biện pháp khắc phục thích hợp phương án khắc phục phụ thuộc vào nguyên nhân ngoại lệ → **hồi quy mạnh** (ví dụ: `MASS::rlm()`)
- độ dị phương sai do biến độc lập gây ra → mô hình LM **dị phương sai** (ví dụ: `spaMM::fitme()` với `resid.model`)
- độ dị phương sai do mối quan hệ giữa biến độc lập và phương sai gây ra → **GLM hồi quy** (ví dụ: `AR1()`, `Matern()` trong `{spaMM}`)
- sự phụ thuộc do nguồn gốc chung → **mô hình hiệu ứng hỗn hợp tuyến tính** (LMM)

Giả định — LM

Bạn có thể kiểm tra trực quan tất cả các giả định về sai số:

```
par(mfrow = c(2, 3)) plot(fit_flipper_3var,  
which = 1:6)
```



Bạn có thể dễ dàng kiểm tra hệ số đòn bẩy⁶ và hệ số ảnh hưởng⁷ của từng điểm:

```
as_tibble(influence.measures(fit_flipper_3var)$infmat)
```

Một bảng: 333 x 9

	dfb.1_	dfb.flp_	dfb.sxml	dfb.spcC	dfb.spcG		dffit	cov.r		cook.d		hat
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	-0,0166	0,0163	-0,0148	0,000177	-0,0115	-0,0211	1,04	0,0000896	0,0244			
2	0,0181	-0,00986	-0,0659	-0,0625		-0,0266	0,150	0,991	0,00450			0,00990
3	0,0741	-0,0797	0,0877	0,0714		0,0953	-0,127	1,02	0,00322			0,0163
4	0,00928	-0,0102	0,0131	0,0109		0,0132	-0,0195	1,03	0,0000766	0,0136		
5	-0,0394	0,0371	-0,0704	0,0347		-0,00728	-0,115	1,01	0,00263			0,0110

i 328 hàng nữa

⁶ mức độ bất thường của một hàng trong ma trận thiết kế

⁷ mức độ ảnh hưởng của một quan sát đến giá trị dự đoán

Cấu trúc mô hình

- tính tuyến tính (đối với biến dự báo
- tuyến tính) không có đa cộng tuyến hoàn
- hảo các biến dự báo có giá trị cố định

Sai số




- độc lập (không có tự tương quan theo chuỗi)
- không có *hiện tượng phân tán quá mức* và *phân tán thiếu* (xem slide tiếp theo)

`plot(fit)` không hữu ích trong trường hợp này vì các giá trị kỳ vọng không giống như của mô hình tuyến tính (LM); thay vào đó, gói {DHARMA} có thể giúp bạn kiểm tra một số giả định này (mặc dù phương pháp mà nó sử dụng không hoàn hảo)

Giải định — GLM

Mô hình GLM giải định một mối quan hệ cụ thể giữa μ và $\text{var}(\mu)$:

```
p <- seq(0, 1, 0.1); lambda <- 0:10; theta <- 0:10 v_b <-  
binomial()$variance(p)  
v_p <- poisson()$variance(lambda) v_G <-  
Gamma()$variance(theta)  
par(mfrow = c(1, 3), las = 1, cex = 1.5) plot(v_b ~ p,  
type = "o")  
plot(v_p ~ lambda, type = "o") plot(v_G  
~ theta, type = "o")
```



Giả định — GLM

Mô hình GLM giả định một mối quan hệ cụ thể giữa μ và $\text{var}(\mu)$

- nếu phương sai tăng nhanh hơn so với giả định, sẽ xảy ra *hiện tượng phân tán quá mức* (thường gặp)
- nếu phương sai tăng chậm hơn so với giả định, sẽ xảy ra *hiện tượng thiếu phân tán* (hiếm gặp)

Giả định — GLM

Mô hình GLM giả định một mối quan hệ cụ thể giữa μ và $\text{var}(\mu)$


- nếu phương sai tăng nhanh hơn so với giả định, sẽ xảy ra *hiện tượng phân tán quá mức* (thường gặp)
- nếu phương sai tăng chậm hơn so với giả định, sẽ xảy ra *hiện tượng phân tán thiếu* (hiếm gặp)

Tình huống điển hình: dữ liệu đếm bị phân tán quá mức so với kỳ vọng Poisson

→ *mô hình nhị thức âm* (ví dụ: {spaMM}, {glmmTMB}, {brms}, {nimble}) và/hoặc *các mô hình bổ sung giá trị 0* (ví dụ: {glmmTMB}, {brms}, {nimble})

Mô hình chiếm dụng môi trường sống

Mô hình chiếm dụng môi trường sống — hãy nhớ lại tình huống



Do đó, chúng ta có một mô hình không gian trạng thái (SSM):

một lớp không quan sát được với biến trạng thái mô tả liệu môi trường sống có bị chiếm dụng hay không một

- kết quả quan sát được mô tả liệu một loài cụ thể có được quan sát thấy hay không mỗi cấp độ này có thể được
- mô hình hóa bằng mô hình GLM logistic
- Hai mô hình GLM này không độc lập với nhau, đây là một mô hình phân cấp

Mô hình chiếm dụng môi trường sống — ước lượng mô hình không có biến giải thích

Đầu tiên, chúng ta mô phỏng dữ liệu và định nghĩa mô hình

```
n_sites <- 100
n_visits <- 50

set.seed(123)
prob_occu <- 0.3; cond_prob_obs <- 0.1 # giá trị thực mô phỏng

occu_truth <- rbinom(n = n_sites, size = 1, prob = prob_occu) obs_mat <-
matrix(NA, nrow = n_sites, ncol = n_visits)

for (site in seq_len(n_sites)) {
  obs_mat[site, ] <- occu_truth[site] * rbinom(n_visits, size = 1, prob = cond_prob_obs)
}

code_occu <- nimbleCode({
  for (site in seq_len(n_sites)) {
    z[site] ~ dbern(prob = psi) # trạng thái có người ở p[site]
    <- z[site] * p_cond # xác suất phát hiện for (visit in
    seq_len(n_visits)) {
      y[site, visit] ~ dbern(p[site]) # kết quả quan sát
    }
  }
  psi ~ dunif(0, 1); p_cond ~ dunif(0, 1)
})
```

Mô hình chiếm dụng môi trường sống — ước lượng mô hình không có biến giải thích

Bây giờ chúng ta có thể ước lượng mô hình

```
constants_occu <- list(n_sites = n_sites, n_visits = n_visits)

z_init <- as.numeric(rowSums(obs_mat) > 0) # Khởi tạo z: bất kỳ phát hiện nào → được coi là đã chiếm chỗ
list(p_cond = 0.5, psi = 0.1, z = z_init)

fit_occu <- nimbleMCMC(code = code_occu,
  constants = constants_occu, data =
  list(y = obs_mat), inits =
  inits_occu,
  nchains = 4, setSeed = 1:4,
  niter = 10000, nburnin = 4000, progressBar =
  FALSE)

summary(as_draws(fit_occu))
```

Một bảng: 2 x 10

biến	trung bình	trung vị	độ lệch chuẩn	mad	q5	q95	rhat	ess_bulk	ess_tail
<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 p_cond	0,0821	0,0820	0,00728	0,00728	0,0704	0,0942	1,00	5465.	5864.
2 psi	0,299	0,298	0,0459	0,0474	0,227	0,377	1,00	5211.	5583.

Mô hình chiếm dụng môi trường sống — ước lượng mô hình với các biến đồng biến

Đầu tiên, chúng ta mô phỏng dữ liệu

```
n_sites <- 100
n_visits <- 50

set.seed(123)
prob_occu <- 0.3 # giá trị thực mô phỏng
occu_truth <- rbinom(n = n_sites, size = 1, prob = prob_occu)

covar_detect_site <- rnorm(n = n_sites) # biến số đồng biến cấp địa điểm

# biến số đồng biến cấp độ lượt ghé thăm, thay đổi theo từng địa điểm VÀ từng lượt ghé thăm
covar_detect_visit <- matrix(rnorm(n = n_sites * n_visits), nrow = n_sites, ncol = n_visits)

# giá trị thực mô phỏng cho hiệu ứng của các biến số
beta0_true <- -2 # hằng số
beta1_true <- 1 # Độ dốc của biến số đồng biến ở cấp
# độ cơ sở beta2_true <- 0.5 # Độ dốc của biến số đồng biến ở
# cấp độ lần thăm khám

p_true <- plogis(beta0_true +
  beta1_true * covar_detect_site + # được tái sử dụng qua các lần thăm khám
  beta2_true * covar_detect_visit) # ma trận địa điểm × lần thăm khám

obs_mat <- matrix(NA_real_, nrow = n_sites, ncol = n_visits)

for (site in seq_len(n_sites))
  obs_mat[site, ] <- occu_truth[site] * rbinom(n_visits, size = 1, prob = p_true[site, ])
```

Mô hình chiếm dụng môi trường sống — ước lượng mô hình với các biến đồng biến

Tiếp theo, chúng ta định nghĩa mô hình

```
code_occu <- nimbleCode({  
  for (site in seq_len(n_sites)) {  
  
    z[site] ~ dbern(prob = psi)  
  
    for (visit in seq_len(n_visits)) {  
  
      logit(p_cond[site, visit]) <- beta0 + beta1 *  
        covar_detect_site[site] +  
        beta2 * covar_detect_visit[site, visit]  
  
      p[site, visit] <- z[site] * p_cond[site, visit] y[site,  
  
      visit] ~ dbern(p[site, visit])  
    }  
  }  
  
  psi ~ dunif(0, 1)  
  beta0 ~ dnorm(0, sd = 10) beta1  
  ~ dnorm(0, sd = 10) beta2 ~  
  dnorm(0, sd = 10)  
})
```

Mô hình chiếm dụng môi trường sống — ước lượng mô hình với các biến đồng biến

Sau đó, chúng ta đặt các hằng số và khởi tạo mô hình

```
constants_occu <- list(n_sites = n_sites,
                      n_visits = n_visits,
                      covar_detect_site = covar_detect_site, covar_detect_visit =
                      covar_detect_visit)

z_init <- as.numeric(rowSums(obs_mat) > 0) # khởi tạo z: bất kỳ phát hiện nào -> được xác định là có người ở

inits_occu <- function() { list(psi =
  runif(1, 0.1, 0.9),
  beta0 = rnorm(1, 0, 1),
  beta1 = rnorm(1, 0, 1),
  beta2 = rnorm(1, 0, 1), z =
  z_init)
}
```

Mô hình chiếm dụng môi trường sống — ước lượng mô hình với các biến đồng biến

Cuối cùng, chúng ta thực hiện việc ước lượng mô hình

```
fit_occu <- nimbleMCMC(code = code_occu,
  constants = constants_occu, data =
  list(y = obs_mat), inits =
  inits_occu,
  nchains = 4, setSeed = 1:4,
  niter = 10000, nburnin = 4000, progressBar =
  FALSE)

summary(as_draws(fit_occu))
```

Một bảng tibble: 4 x 10

biến	trung bình	trung vị	độ lệch chuẩn	mad	q5	q95	rhat	ess_bulk	ess_tail
<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 beta0	-2,15	-2,15	0,102	0,101	-2,32	-1,98	1,00	2309.	3468.
2 beta1	1,04	1,04	0,0951	0,0956	0,886	1,20	1,00	2552.	4260.
3 beta2	0,586	0,584	0,0833	0,0831	0,451	0,724	1,00	3917.	5680.
4 psi	0,299	0,299	0,0460	0,0458	0,224	0,376	1,00	5068.	6133.

Lưu ý: sự phù hợp giữa các tham số thực và các ước lượng của chúng là rất tốt!

Mô hình chiếm dụng môi trường sống — hướng tới các mô hình thực tế hơn

Ngay cả mô hình phức tạp của chúng tôi cũng đưa ra một số giả định khá sơ sài:

- chúng tôi giả định rằng xác suất chiếm dụng thực là cố định ($\psi = 0,3$ trong ví dụ của chúng tôi) và do đó không thay đổi theo thời gian hay không gian
- chúng tôi chỉ xem xét một loài riêng lẻ

Việc nói lỏng các giả định này sẽ làm cho các mô hình trở nên phức tạp hơn nhiều, nhưng may mắn thay, các gói phần mềm như `{nimbleEcology}` hoặc `{unmarked}` (một giải pháp thay thế phi Bayes) đã có sẵn các mô hình được xây dựng sẵn để giúp bạn nói lỏng các giả định này mà hầu như không cần viết mã

Rahel sẽ hướng dẫn bạn cách thực hiện điều đó!

Kết luận

Kết luận

- Việc mô hình hóa có thể khá phức tạp, đặc biệt khi dựa vào phương pháp MCMC
- So sánh kết quả từ các gói phần mềm khác nhau dựa trên các giả định khác nhau có thể hữu ích để xác định các vấn đề (các thiết lập mặc định không phải lúc nào cũng là tốt nhất)
- Mô phỏng dữ liệu là yếu tố quan trọng để đảm bảo rằng bạn thực sự ước lượng được điều bạn mong muốn
- {nimble} rất linh hoạt và có thể làm được nhiều hơn những gì tôi đã trình bày

Có câu hỏi nào không?

Góc dành cho nhà phát triển

Bỏ qua trang trình chiếu này — (thông tin kỹ thuật dành cho Alex)

R phiên bản 4.6.1 (24/06/2026)
Nền tảng: x86_64-redhat-linux-gnu
Chạy trên: Fedora Linux 44 (Phiên bản Môi trường làm việc KDE Plasma)

Sản phẩm ma trận: mặc định
BLAS/LAPACK: FlexiBLAS OPENBLAS-OPENMP; LAPACK phiên bản 3.12.1

Các gói cơ sở đi kèm:
[1] stats đồ họa grDevices tập dữ liệu công cụ phương pháp cơ sở

các gói phần mềm khác được đính kèm:
[1] modelbased_0.16.0 bayesplot_1.15.0 posterior_1.7.0 nimble_1.4.3 brms_2.23.0 Rcpp_1.1.2 lubridate_1.9.5
[8] forcats_1.0.1 stringr_1.6.0 dplyr_1.2.1 purrr_1.2.2 readr_2.2.0 tidyr_1.3.2 tibble_3.3.1
[15] ggplot2_4.0.3 tidyverse_2.0.0

được tải qua không gian tên (và không được gắn):
[1] Rdpack_2.6.6 gridExtra_2.3.1 inline_0.3.21 sandwich_3.1-3 rlang_1.3.0
[6] magrittr_2.0.5 multcomp_1.4-32 otel_0.2.0 matrixStats_1.5.0 compiler_4.6.1
[11] loo_2.10.1 vctr_0.7.3 reshape2_1.4.5 pkgconfig_2.0.3 crayon_1.5.3
[16] fastmap_1.2.0 backports_1.5.1 labeling_0.4.3 utf8_1.2.6 CoprManager_0.5.8
[21] rmarkdown_2.31 tzdb_0.5.0 pracma_2.4.6 nloptr_2.2.1 tinytex_0.60
[26] bit_4.6.0 xfun_0.60 jsonlite_2.0.0 parallel_4.6.1 R6_2.6.1
[31] stringi_1.8.9 RColorBrewer_1.1-3 StanHeaders_2.32.10 boot_1.3-32 numDeriv_2016.8-1.1
[36] estimability_2.0.0 rstan_2.32.7 knitr_1.51 zoo_1.9-0 parameters_0.29.2
[41] Matrix_1.7-6 splines_4.6.1 igraph_2.3.3 thay_đổi_thời_gian_0.4.0 tidyselect_1.2.1
[46] rstudioapi_0.19.0 abind_1.4-8 yaml_2.3.12 codetools_0.2-20 curl_7.1.0
[51] pkgbuild_1.4.8 lattice_0.23-1 plyr_1.8.9 withr_3.0.3 bridgesampling_1.2-1
[56] bayestestR_0.18.1 S7_0.2.2 coda_0.19-4.1 evaluate_1.0.5 hiệu_quả_phụ_biên_0.32.0
[61] survival_3.8-11 RcppParallel_6.2.0 pillar_1.11.1 tensorA_0.36.2.1 checkmate_2.3.4
[66] stats4_4.6.1 reformulas_0.4.4 insight_1.5.2 phân_phoi_0.8.1_các_hàm_chung_0.1.4
[71] vroom_1.7.1 hms_1.1.4 rstantools_2.7.0 scales_1.4.0 minqa_1.2.8
[76] xtable_1.8-8 glue_1.8.1 emmeans_2.0.4 công_cụ_4.6.1 see_0.14.1
[81] data.table_1.18.6.1 lme4_2.0-6 mvtnorm_1.4-2 grid_4.6.1 rbibutils_2.4.1
[86] QuickJSR_1.11.0 datawizard_1.3.1 nlme_3.1-170 cli_3.6.6 Brodningnag_1.2-9
[91] MASS_7.3-66 farver_2.1.2